

MLP - perceptron wielowarstwowy

1 Wstęp

Perceptron wielowarstwowy (ang. Multilayer Perceptron, MLP) jest jednym z najpopularniejszych modeli sieci neuronowych wykorzystywanych w dziedzinie uczenia maszynowego. Jego popularność wynika z faktu, że jest to uniwersalny aproksymator funkcji, umożliwiający modelowanie złożonych nieliniowych relacji między wejściem a wyjściem, w tym tych pomiędzy sygnałami EMG, a ruchem dłoni.

Kolejną przyczyną częstego wykorzystywania perceptronu wielowarstwowego jest fakt, że jest to jeden z najprostszych rodzajów sieci neuronowych, zarówno pod względem zrozumienia, jak i implementacji. W porównaniu do bardziej zaawansowanych modeli, takich jak sieci rekurencyjne czy konwolucyjne, MLP ma bardziej intuicyjną strukturę i łatwiejszy proces uczenia, co czyni go dobrym wyborem dla przypadków, gdzie szybkość i prostota implementacji są priorytetowe.

Dodatkowo podstawowe zasady działania perceptronu wielowarstwowego są dobrze udokumentowane i dostępne w literaturze naukowej. Ponadto, istnieje wiele narzędzi i bibliotek, takich jak TensorFlow czy PyTorch, które ułatwiają implementację i trenowanie perceptronu wielowarstwowego.

2 Opis metody

2.1 Okienkowanie sygnału

Okienkowanie sygnału to proces dzielenia sygnału na krótkie segmenty czasowe, które są następnie analizowane. Jest to szczególnie ważne w przypadku analizy sygnałów biomedycznych takich jak EMG, w celu tworzenia systemów reagujących na intencje człowieka. W przypadku projektowania klasyfikatora dla bionicznej protezy ręki rozpoznanie ruchu, jaki osoba zamierza wykonać, musi nastąpić szybko, aby zachować płynność ruchów. Pod tym względem najbardziej odpowiednie byłoby dokonywanie klasyfikacji na małych fragmentach otrzymywanego sygnału. Jednakże, zbyt krótkie okno może prowadzić do utraty informacji umożliwiających rozróżnienie ruchów między sobą, co skutkuje słabą dokładnością klasyfikatora. Z tego względu ważne jest znalezienie balansu, gdzie wielkość okna jest wystarczająco mała, ale jednocześnie zawiera ono odpowiednią ilość próbek do osiągnięcia dobrej klasyfikacji.

Podczas badań sprawdzono wpływ zmiany długości okna oraz poziomu nachodzenia się okien na działanie klasyfikatora. Przeprowadzona seria badań uwzględniała kilka powszechnie wykorzystywanych rozwiązań. Jedno z nich zakłada zastosowanie okna o długości 200ms oraz poziomu nachodzenia się okien równego 50% [4]. W przypadku drugich badań stwierdzono najlepsze wyniki dla okien o długości 200ms oraz 300ms przy 10, 20 i 30 procentowym nachodzeniu się

okien [2]. Oprócz wymienionych przypadków Autor zbadał również wpływ zastosowania okien rozłącznych, dla każdej z uwzględnionych długości okna.

2.2 Ekstrakcja cech

W przypadku klasyfikacji sygnałów EMG, jednym z kluczowych kroków jest ekstrakcja cech z surowych danych sygnałowych. Sygnały EMG są złożone i składają się z wielu składowych, co utrudnia ich bezpośrednie wykorzystanie do klasyfikacji. Z tego powodu konieczne jest zastosowanie procesu ekstrakcji cech, który pozwala na wyodrębnienie istotnych cech sygnału, które mają znaczenie dla poprawnej klasyfikacji.

Istnieje wiele technik ekstrakcji cech, takich jak metoda korelacji, analiza częstotliwościowa czy metoda czasowo-częstotliwościowa. W przypadku omawianego problemu sprawdzono wpływ kilku różnych podejść na poziom dokładności klasyfikacji sieci, w celu znalezienia najbardziej efektywnego i zarazem najmniej złożonego rozwiązania.

Pierwsza metoda zakłada ekstrakcję cech bezpośrednio z sygnałów EMG. W stworzeniu zbioru istotnych i charakterystycznych cech sygnałów EMG, Autor posłużył się artykułami naukowymi o tej samej tematyce [1, 3, 4]. Spośród cech w nich zawartych wybrano 26. Ich zestawienie przedstawiono w tabeli 1.

Druga metoda również polegała na wyodrębnieniu wybranych cech sygnału, jednakże z uprzednim zastosowaniem analizy falkowej. Polega ona na rozkładzie sygnału na poszczególne składowe falkowe o różnych częstotliwościach i czasach. W wyniku takiej analizy otrzymuje się tzw. transformację falkową, która przedstawia sygnał w dziedzinie czasu i częstotliwości. Dzięki temu można uzyskać bardziej szczegółowe informacje o sygnale i wyodrębnić istotne cechy na różnych poziomach sygnału.

2.3 Selekcja cech

Selekcja cech jest jednym z kluczowych etapów w analizie danych. Polega ona na wybraniu z całego zbioru wyłącznie tych cech, które najbardziej wpływają na predykcję badanego zjawiska. W przeprowadzanym badaniu wybrany zestaw cech jest sporych rozmiarów - 23 cech, uwzględniając wszystkie 6 elektrod, uzyskujemy 138 cech. W przypadku zastosowania analizy falkowej liczba ta zwiększy się jeszcze kilkukrotnie. Sieć neuronowa, która operuje na tak dużej liczbie cech, może wymagać znacznie więcej zasobów obliczeniowych do przetwarzania danych i uczenia modelu. Dokonując procesu selekcji wyłącznie istotnych cech możemy zmniejszyć liczbę parametrów sieci, co przyspieszy proces uczenia i predykcji. Dodatkowo, wybierając tylko te cechy, które faktycznie wpływają na predykcję badanego zjawiska, możemy uniknąć wprowadzania szumu do modelu oraz poprawić jego stabilność.

Wśród dostępnych metod selekcji, można wymienić kilka cieszących się popularnością np. metody oparte na drzewach decyzyjnych - losowy las decyzyjny (Random Forest), analiza głównych składowych (PCA) albo metoda Boruta. W przeprowadzanym badaniu posłużono się trzecią z wymienionych opcji.

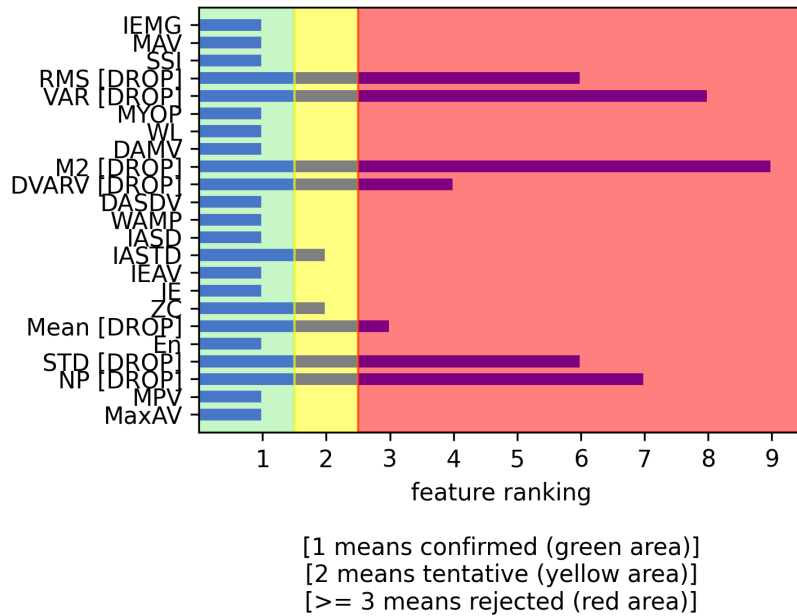
Metoda Boruta jest często wykorzystywana w analizie danych, ze względu na swoją prostotę oraz skuteczność w wyborze istotnych cech. Polega ona na dodawaniu dodatkowych, mało istotnych cech (tzw. cieni) do istniejącego zbioru cech. Następnie z wykorzystaniem algorytmu drzewa decyzyjnego, każda zmienna porównywana jest do najbardziej znaczących cieni. Zostają zachowane wszystkie oryginalne cechy, które są bardziej istotne niż najbardziej znacząca cienia-cień.

Cechy wyznaczono dla każdego kanału oddzielnie, a następnie wyciągnięto średnią, aby uzyskać stały zestaw cech

Tabela 1: Ekstrahowane cechy sygnałów

Metryka	Skrót	Wzór
Zintegrowane EMG	IEMG	$\sum_{n=1}^N x[n] $
Średnia wartości bezwzględna amplitudy sygnału	MAV	$\frac{1}{N} \sum_{n=1}^N x[n] $
Prosta całka kwadratowa sygnału	SSI	$\sum_{n=1}^N x[n]^2$
Wartość skuteczna sygnału	RMS	$\sqrt{\frac{1}{N} \sum_{n=1}^N x[n]^2}$
Wariancja sygnału	VAR	$\frac{1}{N-1} \sum_{n=1}^N x[n]^2$
Procent miopulsu	MYOP	$\frac{1}{N} \sum_{n=1}^N f(x[n]), \quad f(a) = \begin{cases} 1 & a \geq T \\ 0 & a < T \end{cases}$
Długość przebiegu	WL	$\sum_{n=1}^{N-1} x[n+1] - x[n] $
Odchylenie bezwzględne	DAMV	$\frac{1}{N} \sum_{n=1}^{N-1} x[n+1] - x[n] $
Drugi moment centralny	SSI	$\sum_{n=1}^N (x[n+1] - x[n])^2$
Wariancja różnicowa	DVARV	$\frac{1}{N-2} \sum_{n=1}^{N-1} (x[n+1] - x[n])^2$
Różnicowe bezwzględne odchylenie standardowe	DASDV	$\sqrt{\frac{1}{N-1} \sum_{n=1}^{N-1} (x[n+1] - x[n])^2}$
Amplituda Wilsona	WAMP	$\sum_{n=1}^{N-1} f(x[n+1] - x[n]), \quad f(a) = \begin{cases} 1 & a \geq T \\ 0 & a < T \end{cases}$
Zintegrowany moduł drugiej pochodnej	IASD	$\sum_{n=1}^{N-2} (x'[n+1] - x'[n]) $
Zintegrowany moduł trzeciej pochodnej	IATD	$\sum_{n=1}^{N-3} (x''[n+1] - x''[n]) $
Zintegrowana eksponencjalna wartość bezwzględna	IEAV	$\sum_{n=1}^N \exp(x[n])$
Zintegrowana eksponenta	IE	$\sum_{n=1}^N \exp(x[n]) $
Przejście przez zero	ZC	$\sum_{n=1}^{N-1} \text{sign}(x[n+1] \star x[n]) \wedge x[n] - x[n+1] \geq th, \quad \text{sgn}(x) = \begin{cases} 1 & x \geq th \\ 0 & x < th \end{cases}$
Wartość średnia sygnału	Mean	$\frac{1}{N} \sum_{n=1}^N x[n]$
Energia sygnału	EN	$\sum_{n=1}^N x[n] ^2$
Odchylenie standardowe	STD	\sqrt{VAR}
Liczba maksimów	NP	$\sum_{n=1}^N f(x[n]), \quad f(a) = \begin{cases} x[n] & a > RMS \\ 0 & a \leq RMS \end{cases}$
Średnia wartość maksimów	MPV	$\frac{1}{N} NP$
Maksymalna wartość bezwzględna	MaxAV	$\max_i x[n] $

- równy dla wszystkich kanałów. Tym samym powstały 3 zbiory cech, dla których próg akceptacji cechy jako istotnej, na przestrzeni wszystkich klas, wynosił odpowiednio 80%, 90% oraz 100% (test2-test4). Poniżej przedstawiono jeden z wykresów wyboru znaczących cech. Dodatkowo przeprowadzono badania dla wszystkich rozważanych cech (test1) służące



Rysunek 1: Wykres selekcji cech dla kanału 1

jako próba kontrolna oraz uwzględniono przypadek, gdzie cechy charakteryzują się niską złożonością obliczeniową (test5). Wszystkie opisane powyżej przypadki zostały przedstawione w tabeli 2.

Tabela 2: Tabela rozważanych cech

test1	komplet cech
test2	IEMG, MAV, MYOP, DAMV, WAMP, IASTD, IEAV, IALV, IE, ZC, STD, MPV, MaxAV
test3	IEMG, MAV, MYOP, DAMV, WAMP, IASTD, IEAV, IALV, IE, ZC, MPV
test4	MYOP, IEAV, IALV, IE, MPV
test5	IEMG, MAV, SSI, RMS, VAR, WL, IE, Mean, En, STD, MaxAV

2.4 Model sieci

Perceptron wielowarstwowy składa się z jednej lub kilku warstw ukrytych, które przetwarzają wejście i generują wyjście. Każda warstwa ukryta składa się z wielu neuronów, a każdy neuron jest połączony z neuronami z poprzedniej i następnej warstwy. Neurony w warstwach ukrytych wykorzystują nieliniowe funkcje aktywacji, takie jak funkcja sigmoidalna, tangens hiperboliczny lub funkcja ReLU, co pozwala na modelowanie nieliniowych zależności.

W celu zapewnienia najlepszej pracy klasyfikatora, należy odpowiednio dopasować parametry modelu do rozważanego przypadku. Ma to wpływ zarówno na jakość i wydajność sieci, jak również na generalizację modelu, szybkość uczenia się oraz dokładność prognozowania. Aby znaleźć najlepsze parametry sieci MLP, można zastosować techniki optymalizacji,

takie jak Random Search lub Grid Search, które pozwalają na przeszukiwanie przestrzeni parametrów i wybór najlepszej kombinacji. W rozważanym przypadku, do strojenia hiperparametrów, wykorzystano Grid Search. Sprawdzone następujące parametry:

- rozmiary warstw ukrytych (hidden layer sizes): (50,50,50), (50,100,50), (200,150), (150,100),
- funkcja aktywacji (activation): relu, tanh, logistic,
- solver: sgd, adam,
- wartość kary (alpha): 0.0001, 0.001, 0.01,
- współczynnik uczenia (learning rate): constant, adaptive.

W połączeniu z Grid Search, zastosowano dodatkowo walidację krzyżową, która pomaga w ocenie wydajności modelu uczenia maszynowego i zapobiega nadmiernemu dopasowaniu modelu do danych treningowych. Polega ona na podziale zbioru danych na k części (w rozważanym przypadku $k=5$), aby następnie wykonać k iteracji uczenia modelu. W każdej z nich jedna część (za każdym razem inna) służy jako zbiór testowy, a pozostałe jako zbiór treningowy. Ostateczna wydajność modelu jest uśredniana na wynikach uzyskanych na każdej iteracji.

3 Badania wstępne

Pierwszym etapem było przeprowadzenie przeszukiwania hiperparametrów modelu sieci MLP dla różnych sposobów okienkowania i różnych długości wektora cech. Należy również zaznaczyć, że na tym etapie badania wykonywane są bez uwzględnienia analizy falkowej. Uzyskane wyniki przedstawiono w tabelach nr 3, 4, 5, 6, 7. Przeszukiwanie hiperparametrów zostało wykonane dla każdego przypadku z osobna, w celu znalezienia modelu najlepiej dopasowanego do konkretnych warunków wstępnych. Obserwując uzyskane wyniki można zauważyć, że w większości przypadków nie występuje funkcja aktywacji tanh, a warstwy ukryte głównie przyjmują duże wartości - (200,150), (150,100)

Wyniki potwierdzają również, że wraz ze spadkiem ilości cech, spada również dokładność modelu. O ile dla zbioru test2 różnice są niezauważalne oraz dla test 3 lekko zauważalne, to w przypadku test 4 maksymalna dokładność modelu wynosi 52. Jest to znaczna różnica względem zbioru kontrolnego, dla którego dokładność wyniosła 75.9 (Kolorem zielonym zostały zaznaczone najlepsze uzyskane wyniki).

Następnie wybrano 3 najlepsze modele, dla których sprawdzono zachowanie po zastosowaniu analizy falkowej. Modele te mają następującą budowę:

- model 1: okno 600ms i 10%, funkcja aktywacji relu, alpha = 0.0001, warstwy ukryte (200,150),
- model 2: okno 600ms, funkcja aktywacji relu, alpha = 0.01, warstwy ukryte (200,150),
- model 3: okno 600ms i 50%, funkcja aktywacji relu, alpha = 0.001, warstwy ukryte (200,150).

W badaniach wykorzystano różne falki, a wyniki przedstawiono w tabeli 8. Ostatecznie najlepszym modelem okazał się model 1, który uzyskał dokładność na poziomie 0.86 dla coif2.

Tabela 3: Badania wstępne dla zbioru test1

Parametry modelu	Wielkość okna (ilość próbek), stopień nachodzenia	Dokładność zbioru testowego
relu, 0.0001, (200, 150)	200	68.34805365
relu, 0.001, (200, 150)	300	68.6024353
logistic, 0.001 (200, 150)	400	69.23469558
relu, 0.0001, (200, 150)	600	74.12505537
relu, 0.0001, (200, 150)	200, 10%	68.1719886
relu, 0.0001, (200, 150)	200, 20%	68.97949072
relu, 0.0001, (200, 150)	200, 30%	69.58028414
relu, 0.0001, (200, 150)	200, 50%	72.08374223
logistic, 0.01 (200, 150)	300, 10%	69.80760041
logistic, 0.001 (200, 150)	300, 20%	70.10554988
relu, 0.0001, (200, 150)	300, 30%	72.37814851
relu, 0.0001, (200, 150)	300, 50%	73.80272052
relu, 0.0001, (200, 150)	400, 10%	70.5823337
relu, 0.0001, (200, 150)	400, 20%	70.45088065
logistic, 0.001 (150, 100)	400, 30%	71.19786572
relu, 0.0001, (200, 150)	400, 50%	73.69970559
relu, 0.0001, (200, 150)	600, 10%	75.99060827
relu, 0.0001, (200, 150)	600, 20%	70.77442839
relu, 0.0001, (200, 150)	600, 30%	71.87061789
relu, 0.0001, (200, 150)	600, 50%	74.8545863

Tabela 4: Badania wstępne dla zbioru test2

Parametry modelu	Wielkość okna (ilość próbek), stopień nachodzenia	Dokładność zbioru testowego
relu, 0.01 (150, 100)	200	68.4789009
logistic, 0.001 (200, 150)	300	67.4760491
relu, 0.01 (200, 150)	400	67.5769295
relu, 0.01 (200, 150)	600	75.6300343
relu, 0.0001 (200, 150)	200, 10%	69.4149708
logistic, 0.01 (200, 150)	200, 20%	69.6140252
relu, 0.0001 (150, 100)	200, 30%	69.8736472
logistic, 0.0001 (200, 150)	300, 10%	71.5495337
relu, 0.01 (200, 150)	300, 20%	70.1532176
relu, 0.001 (200, 150)	300, 30%	72.6005888
relu, 0.001 (200, 150)	400, 10%	69.9928745
logistic, 0.001 (200, 150)	400, 20%	69.6941392
relu, 0.01 (150, 100)	600, 10%	72.179195
relu, 0.0001 (200, 150)	200, 50%	71.988878
relu, 0.0001 (50, 50, 50)	300, 50%	73.7513099
relu, 0.0001 (150, 100)	400, 30%	68.9737362
relu, 0.01 (50, 50, 50)	400, 50%	74.5829244
relu, 0.01 (200, 150)	600, 20%	71.0896578
relu, 0.0001 (200, 150)	600, 30%	72.1976316
relu, 0.001 (200, 150)	600, 50%	75.1040006

Tabela 5: Badania wstępne dla zbioru test3

Parametry modelu	Wielkość okna (ilość próbek), stopień nachodzenia	Dokładność zbioru testowego
relu, 0.0001 (200, 150)	200	65.61334642
relu, 0.001 (200, 150)	300	65.62675321
relu, 0.0001 (200, 150)	400	67.02934162
relu, 0.001 (200, 150)	600	69.56231691
relu, 0.001 (200, 150)	200, 10%	65.60422836
relu, 0.0001 (200, 150)	200, 20%	65.73409265
relu, 0.0001 (50, 50, 50)	200, 30%	67.06512681
relu, 0.001 (50, 50, 50)	200, 50%	68.99901865
logistic, 0.001 (150, 100)	300, 10%	67.11676507
relu, 0.01 (200, 150)	300, 20%	66.56452162
relu, 0.001 (150, 100)	300, 30%	67.36015702
relu, 0.0001 (200, 150)	300, 50%	71.21378259
relu, 0.001 (200, 150)	400, 10%	67.92172675
logistic, 0.001 (150, 100)	400, 20%	66.9508298
logistic, 0.001 (200, 150)	400, 30%	68.79335571
relu, 0.0001 (200, 150)	400, 50%	71.7631665
relu, 0.0001 (200, 150)	600, 10%	70.03595837
relu, 0.001 (200, 150)	600, 20%	68.33615807
relu, 0.001 (150, 100)	600, 30%	68.73221727
relu, 0.0001 (200, 150)	600, 50%	71.32858107

Tabela 6: Badania wstępne dla zbioru test4

Parametry modelu	Wielkość okna (ilość próbek), stopień nachodzenia	Dokładność zbioru testowego
logistic, 0.001 (200, 150)	200	47.6545633
logistic, 0.001 (200, 150)	300	47.61889071
logistic, 0.001 (150, 100)	400	48.03587673
logistic, 0.001 (150, 100)	600	51.19537827
logistic, 0.01 (150, 100)	200, 10%	48.27264329
logistic, 0.01 (200, 150)	200, 20%	48.44979609
logistic, 0.001 (150, 100)	200, 30%	48.10165074
relu, 0.001, (150, 100)	200, 50%	51.76643768
relu, 0.001 (150, 100)	300, 10%	48.46348531
logistic, 0.01 (200, 150)	300, 20%	49.48586994
logistic, 0.001 (200, 150)	300, 30%	49.89205103
logistic, 0.001 (200, 150)	300, 50%	49.76436433
logistic, 0.01 (200, 150)	400, 10%	49.96352874
relu, 0.001 (200, 150)	400, 20%	48.71971449
logistic, 0.001 (150, 100)	400, 30%	52.20937219
logistic, 0.001 (200, 150)	400, 30%	49.69826117
tanh, 0.01 (50, 50, 50)	400, 50%	50.1537455
logistic, 0.01 (150, 100)	600, 20%	50.45055809
logistic, 0.01 (200, 150)	600, 30%	49.29626366
logistic, 0.001 (150, 100)	600, 50%	51.36870718

Tabela 7: Badania wstępne dla zbioru test5

Parametry modelu	Wielkość okna (ilość próbek), stopień nachodzenia	Dokładność zbioru testowego
relu, 0.001, (200, 150)	200	70.04252535
relu, 0.0001, (200, 150)	300	68.12956851
relu, 0.001, (200, 150)	400	69.59609595
relu, 0.01, (200, 150)	600	73.74969388
relu, 0.001, (200, 150)	200, 10%	70.31441477
relu, 0.001, (200, 150)	200, 20%	70.08533163
relu, 0.01, (200, 150)	200, 30%	70.23834539
relu, 0.0001, (200, 150)	200, 50%	73.05201178
relu, 0.001, (200, 150)	300, 10%	70.34735731
relu, 0.001, (200, 150)	300, 20%	69.96254682
relu, 0.01, (200, 150)	300, 30%	72.14916585
relu, 0.001, (200, 150)	300, 50%	74.48970958
relu, 0.001, (200, 150)	400, 10%	72.54495913
relu, 0.0001, (200, 150)	400, 20%	70.90671326
relu, 0.0001, (200, 150)	400, 30%	72.73474827
relu, 0.001, (200, 150)	400, 50%	74.17075564
relu, 0.01, (200, 150)	600, 10%	75.15584414
relu, 0.001, (200, 150)	600, 20%	72.69959959
relu, 0.001, (200, 150)	600, 30%	74.47279308
relu, 0.001, (200, 150)	600, 50%	77.37422868

Tabela 8: Zestawienie dokładności dla analizy falkowej

	model1	model2	model3		model1	model2	model3
db1	0.84	0.81	0.83	bior3.7	0.79	0.79	0.82
db2	0.84	0.77	0.83	bior3.9	0.78	0.74	0.81
db3	0.84	0.81	0.83	bior4.4	0.84	0.80	0.81
db4	0.85	0.81	0.82	bior5.5	0.79	0.80	0.82
db5	0.81	0.81	0.83	bior6.8	0.81	0.80	0.81
db6	0.78	0.79	0.81	coif1	0.84	0.83	0.85
db7	0.83	0.81	0.84	coif2	0.86	0.82	0.83
db8	0.83	0.79	0.82	coif3	0.80	0.77	0.82
db9	0.81	0.79	0.81	coif4	0.82	0.76	0.81
db10	0.82	0.78	0.82	coif5	0.81	0.79	0.81
db11	0.82	0.78	0.82	coif6	0.82	0.75	0.81
db12	0.81	0.82	0.80	sym2	0.82	0.77	0.83
db13	0.79	0.78	0.82	sym3	0.84	0.79	0.83
db14	0.82	0.80	0.80	sym4	0.84	0.82	0.85
db15	0.78	0.78	0.81	sym5	0.84	0.78	0.84
bior1.1	0.84	0.81	0.83	sym6	0.82	0.81	0.84
bior1.3	0.83	0.83	0.81	sym7	0.83	0.80	0.82
bior1.5	0.83	0.82	0.84	sym8	0.82	0.82	0.81
bior2.2	0.85	0.80	0.83	sym9	0.81	0.76	0.83
bior2.4	0.83	0.81	0.82	sym10	0.81	0.80	0.81
bior2.6	0.82	0.81	0.81	sym11	0.83	0.76	0.83
bior2.8	0.82	0.81	0.80	sym12	0.82	0.79	0.83
bior3.1	0.78	0.69	0.75	sym13	0.82	0.78	0.81
bior3.3	0.82	0.77	0.80	sym14	0.79	0.75	0.82
bior3.5	0.81	0.79	0.80	sym15	0.84	0.78	0.81

Literatura

- [1] Sara Abbaspour, Maria Lindén, Hamid Gholamhosseini, Autumn Naber, and Max Ortiz-Catalan. Evaluation of surface emg-based recognition algorithms for decoding hand movements. *Medical Biological Engineering Computing*, 58, 11 2019.
- [2] Hassan Ashraf, Asim Waris, Syed Omer Gilani, Amer Sohail Kashif, Mohsin Jamil, Mads Jochumsen, and Imran Khan Niazi. Evaluation of windowing techniques for intramuscular emg-based diagnostic, rehabilitative and assistive devices. *Journal of Neural Engineering*, 18(1):016017, feb 2021.
- [3] Reza Bagherian Azhiri, Mohammad Esmaili, and Mehrdad Nourani. Emg-based feature extraction and classification for prosthetic hand control, 2021.
- [4] Axel Forsberg. A wavelet-based surface electromyogram feature extraction for hand gesture recognition. 2018.