

Politechnika Wrocławska

Wydział Informatyki i Telekomunikacji

KIERUNEK: Informatyczne systemy automatyki (ISA)

PRACA DYPLOMOWA MAGISTERSKA

TYTUŁ PRACY:
Sterowanie decyzyjne protezą ręki z
wykorzystaniem samo-organizującej się sieci
neuronowej

AUTOR:
Leonard Feszczuk

PROMOTOR:
Dr inż. Andrzej Wołczowski

Spis treści

1	SOM	5
1.1	Samo organizujące się sieci Kohonnena	5
1.2	Ekstrakcja cech	6
1.3	Wyniki badań wstępnych	8
	Literatura	8

Skróty

SOM – Self organizing map – samoorganizująca sieć

BMU – Best Matching Unit – Jednostka najbardziej dopasowana

EMG – Elektromiografia

IDE – Integrated Development Environment – Zintegrowane środowisko programistyczne

Rozdział 1

SOM

1.1 Samo organizujące się sieci Kohonnena

W pracy magisterskiej będę wykorzystywał samo organizujące się sieci(SOM) do klasyfikacji sygnałów pochodzących z kikuta ręki. Sieci te mogą być wykorzystywane w celu ograniczenia wymiarowości danych ponieważ zawsze otrzymamy dane z rzutowane na 2-wymiarową przestrzeń. Obiekt wejściowy jest klasyfikowany poprzez metrykę odległości do węzłów 1.1. Po obliczeniu odległości zostaje wybrany ten o najmniejszej z nich, jest to tak zwany BMU (best matching unit) przykładowy wzór na odległość od węzła wyglądałby tak:


$$Distance = \sqrt{\sum (x_i - w_{1,i})^2}$$

Gdzie:

x_i - i-ta cecha wejściowa

$w_{1,i}$ - i-ty element wektora opisującego pierwszy węzeł

Podczas procesu uczenia się sieć coraz dokładniej stara się dopasować do danych tworząc



Rysunek 1.1: Rzutowanie danych na przestrzeń 2D

maskę dzięki której będzie można sklasyfikować dane przychodzące do konkretnego obszaru

1.2. Po znalezieniu BMU następuje krok aktualizowania wag węzłów sieci. Obliczane są one według wzoru:

$$w_i(t+1) = w_i(t) + \eta(t)h(c_i, BMU(t))(x(t) - w_i(t)) \quad (1.1)$$

Gdzie:

t - obecna iteracja w procesie uczenia. W naszym przypadku t zwiększa się o 1 za każdym razem gdy aktualizowane są wagi węzłów.


$w_i(t)$ - i -ty wektor wag w czasie t

$\eta(t)$ - wartość współczynnika uczenia się w czasie t

$h(c_i, BMU(t))$ - funkcja sąsiedztwa określająca które węzły będą zaktualizowane

$x(t)$ - wektor wejściowy w czasie t

$BMU(t)$ - indeks BMU w czasie t



Rysunek 1.2: Tworzenie się maski na przestrzeni danych

Powyższe równanie można rozwinąć uwzględniając promień sąsiedztwa inaczej $\sigma(\sigma)$.

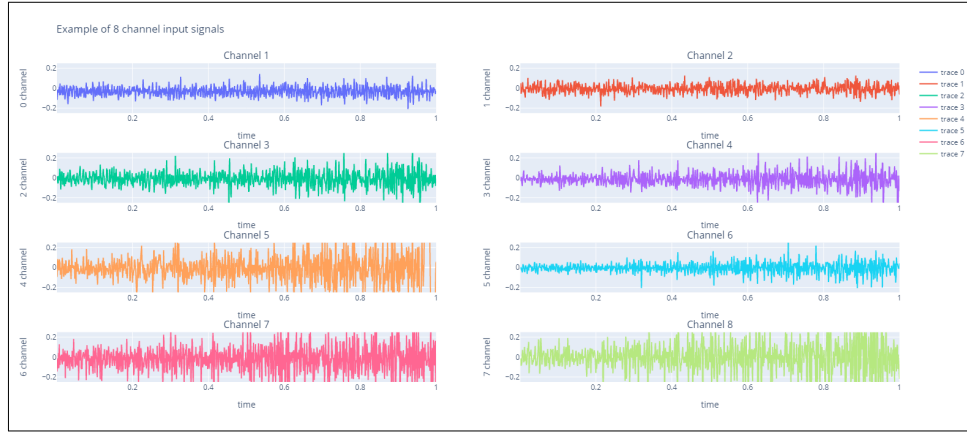
$$w_i(t+1) = w_i(t) + \eta(t)h\left(\frac{|c_i - BMU(t)|}{\sigma(t)}\right)(x(t) - w_i(t)) \quad (1.2)$$

W kolejnych epokach promień coraz bardziej się zmniejsza, sieć coraz bardziej się dopasowuje, stają się dokładniejsze.

1.2 Ekstrakcja cech

Danymi wejściowymi są pomiary EMG z mięśni kikutu jednej osoby. Pomiary zebrano przy użyciu elektrod oraz systemu pomiarowego ze wzmacniaczem, zamieniającego sygnały analogowe na cyfrowe[3]. Dla każdego z sześciu gestów posiadany zbiór to 10 próbek jedno sekundowych z częstotliwością 1kHz. Każdy pomiar składa się z ośmiu kanałów czujników.

Dane te zostały poddane obróbce w celu lepszego scharakteryzowania każdej próbki, inaczej mówiąc w celu ekstrakcji cech. W pierwszym kroku zestaw uczący został poddany transformacji falkowej. Transformata falkowa okazuje się bardzo użyteczna w badaniach sygnałów EMG, jest szczególnie użyteczna przy wyłapywaniu informacji w dziedzinie zarówno czasu jak i częstotliwości. Aby skutecznie korzystać z transformaty ważne jest aby odpowiednio dobrać poziom dekompozycji oraz rodzaj falki. Po poddaniu sygnału transformacji następuje etap ekstrakcji wybranych cech. Z każdego obiektu zostały wybrane konkretne jego właściwości przedstawione w tabeli[1].



Rysunek 1.3: Surowe dane wejściowe

Statistical Metric	Abbreviation	Formula
Integrated EMG	IEMG	$\sum_{n=1}^N x[n] $
Mean Absolute Value	MAV	$\frac{1}{N} \sum_{n=1}^N x[n] $
Simple Square Integrated	SSI	$\sum_{n=1}^N x[n]^2$
Root Mean Square	RMS	$\sqrt{\frac{1}{N} \sum_{n=1}^N x[n]^2}$
Variance	VAR	$\frac{1}{N-1} \sum_{n=1}^N x[n]^2$
Myopulse Percentage Rate	MYOP	$\frac{1}{N} \sum_{n=1}^N f(x[n]), \quad f(a) = \begin{cases} 1 & \text{if } a > T \\ 0 & \text{otherwise} \end{cases}$
Waveform Length	WL	$\sum_{n=1}^{N-1} x[n+1] - x[n] $
Difference Absolute Mean Value	DAMV	$\frac{1}{N-1} \sum_{n=1}^{N-1} x[n+1] - x[n] $
Second-Order Moment	M2	$\sum_{n=1}^{N-1} (x[n+1] - x[n])^2$
Difference Variance Version	DVARV	$\frac{1}{N-2} \sum_{n=1}^{N-1} (x[n+1] - x[n])^2$
Difference absolute standard deviation value	DASDV	$\sqrt{\frac{1}{N-1} \sum_{n=1}^{N-1} (x[n+1] - x[n])^2}$
Willison Amplitude	WAMP	$\sum_{n=1}^{N-1} f(x[n+1] - x[n]), \quad f(a) = \begin{cases} 1 & \text{if } a > T \\ 0 & \text{otherwise} \end{cases}$

Rysunek 1.4: Tabla zestawu ekstrapolowanych cech [1]

Po etapie preprocessingu następuje właściwe uczenie. Wynikowe cechy zostaną podane na różne rodzaje sieci klasyfikujących. Wybranymi klasyfikatorami są:

Generalized Learning Vector Quantization (GLVQ) - Główną różnicą między regularnym algorytmem LVQ a zgeneralizowanym jest przyjęcie możliwości użycia innych metryk niż liniowe oraz możliwość użycia więcej niż jednego wektora prototypowego opisującego dany węzeł co może zwiększyć dokładność algorytmu.

Generalized Matrix Learning Vector Quantization (GMLVQ)- To odmiana LVQ, która została zaprojektowana do obsługi danych reprezentowanych jako macierze lub tensory. Takie dane możemy często spotkać w dziedzinach takich jak przetwarzanie obrazów i sygnałów. W GMLVQ każda klasa jest reprezentowana przez zestaw prototypowych macierzy lub tensorów, które są iteracyjnie dostosowywane podczas procesu uczenia, aby lepiej reprezentować klasę, z którą są związane. Główną przewagą GMLVQ nad innymi

algorytmami klasyfikacji opartymi na macierzach jest jego zdolność do obsługi nieliniowych związków między danymi wejściowymi a klasami wyjściowymi. GMLVQ osiąga to poprzez wykorzystanie nieliniowej funkcji transformacji, która mapuje dane wejściowe na przestrzeń o wyższej liczbie wymiarów, gdzie liniowe związki między prototypowymi macierzami a danymi wejściowymi mogą być łatwiej uchwycone [2].

Robust Soft Learning Vector Quantization (RSLVQ) - RSLVQ wprowadza tzw. "miękką" klasteryzację, która pozwala na przypisanie każdego punktu danych wejściowych do każdej z klas z określonym prawdopodobieństwem, zamiast jednoznacznie przypisać każdy punkt danych do tylko jednej klasy. To oznacza, że każdy punkt danych może być częściowo przypisany do jednej klasy i częściowo do innej, co pozwala na bardziej subtelne rozróżnienie pomiędzy klasami, zwłaszcza w przypadkach, gdy granice pomiędzy klasami są niejednoznaczne lub złożone. RSLVQ stosuje również dodatkowe techniki w celu zwiększenia odporności na szumy, takie jak ograniczenie wpływu odległych punktów danych, które mogą być szumem, na proces uczenia, oraz wykorzystanie nieciągłych funkcji aktywacji, które łagodnie reagują na zmiany w danych wejściowych.

Z tych klasyfikatorów zostanie wybrany najlepszy i dla tylko tego jednego zostanie zaimplementowany mechanizm uczenia przez wzmacnianie. Dzięki temu będzie możliwe dopasowywanie się z czasem sieci do zmieniających się sygnałów wejściowych związanych z eksploatacją protezy, czy też sposobem użycia przez pacjenta. Po otrzymaniu wynikowego modelu zostanie on zaimplementowany na mikro-kontrolerze Raspberry Pi 4b ze względu na moc obliczeniową oraz łatwość użycia z bibliotekami tensor flow.

1.3 Wyniki badań wstępnych

Literatura

- [1] R. B. Azhiri, M. Esmaeili, M. Nourani. Emg-based feature extraction and classification for prosthetic hand control, 2021.
- [2] P. Schneider, M. Biehl, B. Hammer. Distance learning in discriminative vector quantization. *Neural Computation*, 21(10):2942–2969, 2009.
- [3] A. Wołczowski, M. Błędowski, J. Witkowski. The system for emg and mmg singals recording for the bioprosthetic hand control. 2017. [Online: 21.12.2021].

Spis tabel

Spis rysunków

1.1	Rzutowanie danych na przestrzeń 2D	5
1.2	Tworzenie się maski na przestrzeni danych	6
1.3	Surowe dane wejściowe	7
1.4	Tabla zestawu ekstrapolowanych cech [1]	7