

Politechnika Wrocławska
Wydział Elektroniki

Kierunek: Automatyka i Robotyka (AIR)
Specjalność: Komputerowe Systemy Zarządzania Procesami
Produkcyjnymi (ARS)

PRACA DYPLOMOWA
(MAGISTERSKA)

**Analiza wektora sygnałów rejestrowanych
z mięśni przedramienia człowieka w
sterowaniu bio-manipulatorem**

Autor:
Tomasz Białobrzeg

Prowadzący pracę:
dr inż. Andrzej Wołczowski

/pieczęć jednostki
prowadzącej specjalność/

Ocena pracy:
/stopień, słownie, podpis odręczny/

Wrocław 2003

Spis treści

1. WSTĘP	3
2. CEL I ZAKRES PRACY.....	4
3. BUDOWA PRZEDRAMIENIA CZŁOWIEKA	6
3.1 INFORMACJE OGÓLNE	6
3.2 MIĘSNIE PRZEDRAMIENIA	7
4. AKTYWNOŚĆ ELEKTRYCZNA MIĘŚNI.....	10
4.1 CO TO JEST SYGNAŁ EMG?.....	10
4.2 POŁOŻENIE ELEKTROD POMIAROWYCH	10
4.3 NATURA SYGNAŁU EMG	11
5. POMIAR MIOPOTENCJAŁÓW	13
5.1 ZADANIE UKŁADU POMIAROWEGO	13
5.2 WYMAGANIA STAWIANE WZMACNIACZOM INSTRUMENTALNYM.....	13
5.3 ELEKTRODY EMG	18
5.4 PROJEKT UKŁADU POMIAROWEGO	20
6. PRÓBKOWANIE SYGNAŁU	25
6.1 CO TO JEST PRÓBKOWANIE?.....	25
6.2 CZĘSTOTLIWOŚĆ PRÓBKOWANIA	25
6.3 KRYTERIUM NYQUISTA	27
6.4 TRANSFORMATY FOURIERA.....	28
6.5 EFEKT MIESZANIA CZĘSTOTLIWOŚCI	29
7. ROZPOZNAWANIE STANU DŁONI NA PODSTAWIE EMG.....	32
7.1 PODSTAWY ROZPOZNAWANIA OBIEKTÓW	32
7.2 BAYESOWSKA TEORIA DECYZJI	35
7.3 ALGORYTM ROZPOZNAWANIA K-NN.....	39
7.4 PROBLEM ROZPOZNAWANIA STANU DŁONI.....	40
7.5 OCENA JAKOŚCI ROZPOZNAWANIA	41
8. OPIS PROGRAMU ANALIZATOR MIOPOTENCJAŁÓW.....	43
8.1 OGÓLNA KONCEPCJA PROGRAMU	43
8.2 BLOKI FUNKCYJONALNE	43
8.3 PRZYKŁADY RÓŻNYCH KONFIGURACJI	52
9. BADANIA	55
9.1 PLAN EKSPERYMENTÓW	55
9.2 ROZMIESZCZENIE ELEKTROD EMG	55
9.3 BAZA DANYCH SYGNAŁÓW EMG	56
9.4 EKSPERYMENTY	56
10. PODSUMOWANIE	59
11. LITERATURA	60

1. Wstęp

Podstawowym zadaniem protezy dłoni jest odtworzenie funkcji ruchowych utraconej kończyny tj. umożliwienie jej posiadaczowi wykonywanie wszystkich operacji, które są możliwe przy użyciu naturalnej dłoni. Zadanie tak postawione jest bardzo trudne w realizacji, ponieważ wymaga rozwiązania całego szeregu problemów z różnych obszarów wiedzy. Najważniejszymi zagadnieniami, które pojawiają się w pracach nad protezą są: budowa mechaniczna oraz sterowanie. Zadaniem układu mechanicznego jest zastąpienie elementów mechanicznych utraconej dłoni takich jak: kości, mięśnie, skóra, itp. Układ ten powinien być tak zaprojektowany, aby nie tylko odtwarzał zachowanie się naturalnej dłoni, lecz także, aby kształt całej protezy był zbliżony do naturalnego gdyż bardzo często okazuje się, że względy estetyczne odgrywają główną rolę w przekonaniu pacjenta do jej używania. Zadaniem układu sterowania jest umożliwienie sterowania protezą przez jej posiadacza, najlepiej w taki sposób, w jaki steruje się zachowaniem naturalnej dłoni, tj. przy użyciu impulsów nerwowych doprowadzanych z mózgu do mięśni przedramienia człowieka. Bezpośrednia detekcja impulsów nerwowych jest bardzo trudna, ponieważ do jej uzyskania konieczne jest zastosowanie inwazyjnej metody pomiaru polegającej na wkłuwaniu się elektrodami igłowymi [12] w niewielkie doprowadzenia nerwowe lub też w pojedyncze włókna mięśniowe. Z tego też powodu obecnie prowadzone prace nad sterowaniem protezą idą w kierunku wykorzystania innych źródeł informacji o zmianie stanu dłoni, takich jak np. miopotencjały [6] [7] tj. sygnały napięciowe będące wynikiem elektrycznej aktywności mięśni lub drgania mięśni mierzone akcelerometrami.

2. Cel i zakres pracy

Celem tej pracy jest analiza sygnałów elektrycznych rejestrowanych z mięśni (miopotencjałów) przedramienia człowieka pod kątem wykorzystania ich w sterowaniu aktywną protezą dłoni.

W rozdziale 3 przedstawiono budowę układu mięśniowego przedramienia ze szczególnym uwzględnieniem mięśni odpowiedzialnych za zmianę stanu dłoni. Pokazano tam, między innymi, położenie poszczególnych mięśni przedramienia oraz opisano funkcje, jaką spełniają w układzie ruchowym człowieka.

Wprowadzenie do elektromiografii przedstawiono w rozdziale 4 gdzie podano definicję, co należy rozumieć pod pojęciem miopotencjałów. W rozdziale tym zawarto też podstawowe informacje o amplitudowej, częstotliwościowej i statystycznej naturze mierzonych sygnałów.

Budowa i projekt układu pomiarowego, bez którego nie byłoby możliwe rejestrowanie sygnału EMG, została przedstawiona w rozdziale 5. Ze względu na fakt, że w ramach pracy magisterskiej zaprojektowano i wykonano dwa układy pomiarowe, rozdział 5 zawiera także skrócony opis pierwszego, prototypowego układu.

Rozdział 6 zawiera niezbędne informacje na temat teoretycznych i praktycznych aspektów tego, w jaki sposób następuje zamiana reprezentacji sygnału z ciągłej na dyskretną (zarówno w dziedzinie czasu jak i amplitudy) oraz wyjaśnia, czym jest transformata Fouriera, wykorzystywana tutaj jako podstawowe narzędzie w ekstrakcji informacji z mierzonych sygnałów.

Zadanie sterowania protezą postawiono jako problem rozpoznawania stanu dłoni na podstawie elektrycznej aktywności mięśni przedramienia. Rozdział 7 zawiera wprowadzenie w problematykę teorii rozpoznawania, zdefiniowano tam także w sposób formalny zbiór stanów dłoni (obiektów rozpoznawania), które są używane w rozdziale 9 dotyczącym przeprowadzonych badań. Przydatność badanych sposobów ekstrakcji informacji określono na podstawie błędów rozpoznawania stanu dłoni, do rozpoznawania użyto klasyczny algorytm k – najbliższych sąsiadów (ang. k -NN) opisany także w rozdziale 7. Więcej informacji na temat innych algorytmów rozpoznawania, w tym także neuronowych, można znaleźć w pracy magisterskiej autorstwa Sebastiana Busza pt. „Zastosowanie sieci neuronowych do sterowania bio-manipulatorem”. W pracy tej, kolega Busz wykorzystuje przedstawiony tutaj układ pomiarowy aby ocenić przydatność różnego rodzaju sieci neuronowych w procesie rozpoznawania.

Wszystkie prowadzone w tej pracy badania zostały wykonane z użyciem specjalnie stworzonego -na potrzeby tej pracy- programu komputerowego. Ogólna koncepcja, którą kierowano się tworząc ten program, wraz z opisem jego działania i możliwościami została przedstawiona w rozdziale 8.


3. Budowa przedramienia człowieka

3.1 Informacje ogólne

Przedramię człowieka jest częścią aparatu ruchowego umożliwiającego poruszanie się oraz przenoszenie obiektów. Aparat ruchowy stanowi połączenie różnych struktur takich jak: układ kostny, mięśniowy, stawowy i nerwowy.

- **Układ kostny**

Szkielet dorosłego człowieka składa się z ponad dwustu kości, tworzy on sztywną część aparatu ruchowego i decyduje o wytrzymałości, formie i rozmiarach ciała.



Rysunek 3.1 Kości przedramienia człowieka wraz z dłonią.

- **Układ mięśniowy**


Układ mięśniowy jest aktywną częścią aparatu ruchowego. Poszczególne mięśnie uaktywniają się po otrzymaniu – za pośrednictwem nerwów obwodowych - odpowiedniego impulsu z ośrodkowego układu nerwowego. Mięśnie stanowią około 30-40% ciężaru ciała, jest ich powyżej czterystu.


- **Stawy**

Są to skomplikowane struktury, stanowiące połączenie kości. Pozwalają na wykonywanie, ruchów, zmniejszając w znacznym stopniu tarcie. Przylegające do nich struktury określają odpowiednią rozległość ruchów oraz zapewniają stały bliski kontakt poszczególnych powierzchni.

3.2 Mięśnie przedramienia

Wszystkie ruchy ciała są wynikiem skurczów mięśni, działających na układ dźwigni utworzony przez kości i stawy. W przypadku przedramienia można, w pewnym uproszczeniu, powiedzieć, że wszystkie mięśnie znajdujące się na przedniej powierzchni przedramienia zginają rękę i palce, natomiast osadzone na tylnej powierzchni są prostownikami ręki i palców. Dalej przedstawiono wybrane mięśnie przedramienia wraz z opisem ruchów dłoni i przedramienia za jakie są odpowiedzialne.





Rysunek 3.2 Wybrane mięśnie przedramienia człowieka.

Nazwa łacińska mięśnia	Spełniana funkcja
<i>Flexor digitorum superficialis</i>	Zginanie nadgarstka, zginanie bliższego i środkowego palczyka palców.
<i>Flexor pollicis longus</i>	Zginanie palczyków kciuka.
<i>Pronator quadratus</i>	Pronacja (odwracanie do wewnątrz) przedramienia.
<i>Flexor digitorum profundus</i>	Zginanie palców, dodatkowo zginanie palczyków dalszych palców, słabe zginanie nadgarstka.
<i>Pronator teres</i>	Pronacja (odwracanie do wewnątrz) i zginanie przedramienia
<i>Flexor carpi radialis</i>	Zginanie i odwodzenie dłoni w nadgarstku.
<i>Palmaris longus</i>	Zginanie dłoni w nadgarstku.
<i>Flexor carpi ulnaris</i>	Zginanie i odwodzenie dłoni w nadgarstku.
<i>Abductor pollicis longus</i>	Odwodzenie i prostowanie kciuka.
<i>Extensor pollicis longus</i>	Prostowanie kciuka.
<i>Extensor pollicis brevis</i>	Prostowanie kciuka.
<i>Extensor indicis</i>	Prostowanie palca wskazującego
<i>Extensor digitorum</i>	Wspomaga prostowanie połączeń międzypalczymi w palczykach: bliższym i dalszym, prostuje śródreżce.
<i>Extensor digiti minimi</i>	Wspomaga prostowanie małego palca.
<i>Transverse head</i>	Supinacja (odwracanie na zewnątrz) szczytu kości łokciowej.
<i>Oblique head</i>	Supinacja (odwracanie na zewnątrz) przedramienia, wspomaga mięsień <i>biceps brachii</i> który jest głównym supinatorem przedramienia.

Tabela 3.1 Mięśnie przedramienia człowieka wraz z funkcją jaką spełniają.

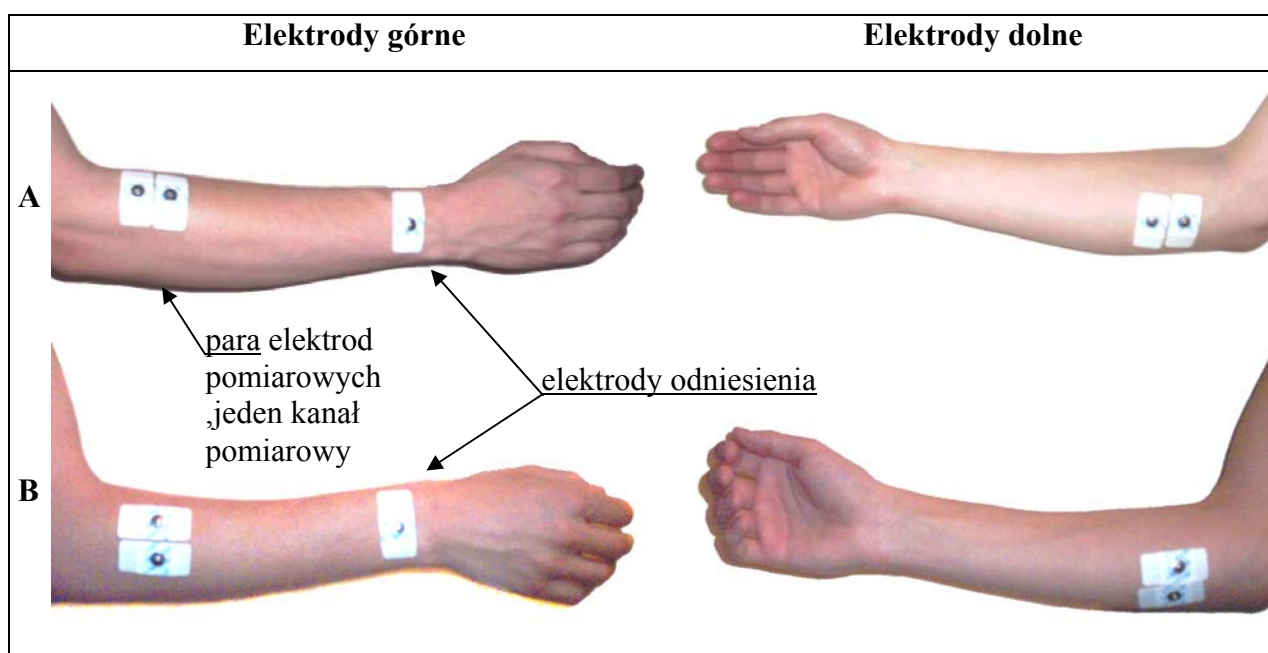
4. Aktywność elektryczna mięśni

4.1 Co to jest sygnał EMG?

EMG¹ jest to sygnał elektryczny (napięciowy) mierzony we wnętrzu lub na powierzchni mięśni. Jego istnienie jest wynikiem elektrycznej aktywności organów człowieka.

4.2 Położenie elektrod pomiarowych

Szczegóły dotyczące pomiaru i przetwarzania sygnałów EMG zostaną podane w dalszej części pracy. Tutaj jedynie ograniczymy się do pokazanie punktów pomiarowych (miejsc gdzie zostały zamocowane elektrody pomiarowe) służących do zbierania miopotencjałów, aby już teraz zobrazować w jaki sposób uzyskuje się EMG.




Rysunek 4.1 Ułożenie elektrod EMG wykorzystywane podczas pomiarów;
A- poprzecznie do włókien mięśniowych,
B – wzdłuż włókien mięśniowych.

¹ elektromiograf, ang. electromyography

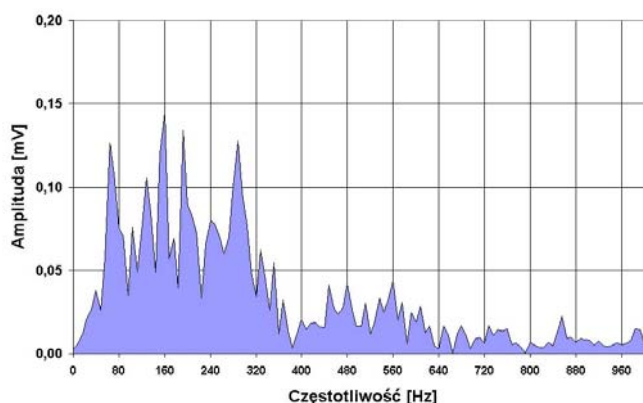
4.3 Natura sygnału EMG

Sygnał EMG ma charakter stochastyczny, zmierzona wartość chwilowa tego sygnału może być traktowana jako realizacja zmiennej losowej, której gęstość prawdopodobieństwa ma rozkład normalny. Amplituda EMG może zmieniać się w przedziale od 0 do 10mV (wartość międzyszczytowa) lub od 0 do 1.5 mV (wartość skuteczna). Widmo EMG zawiera się w przedziale od 0 do 500Hz (patrz rysunek 4.3), przy czym główna część energii niosącej użyteczną informację znajduje się w paśmie 50-150Hz. Widmo sygnału EMG mierzonego na powierzchni skóry nie jest stałe, na jego parametry mają wpływ następujące czynniki:

- rozmiar mięśnia będącego źródłem sygnału,
- odległość mięśnia od miejsca zamocowania elektrod,
- orientacja elektrod pomiarowych względem włókien mięśniowych,
- stan mięśnia: naprężenie / rozluźnienie,
- zmęczenie lub brak zmęczenia mięśnia.




Rysunek 4.2 Sygnał EMG z dwóch kanałów, mierzony na wewnętrznej i zewnętrznej powierzchni przedramienia (ułożenie typu A) podczas zginania i prostowania nadgarstka; wartość międzyszczytowa wynosi 2 mV.




Rysunek 4.3 Widmo wycinka sygnału przedstawionego na rysunku 4.2

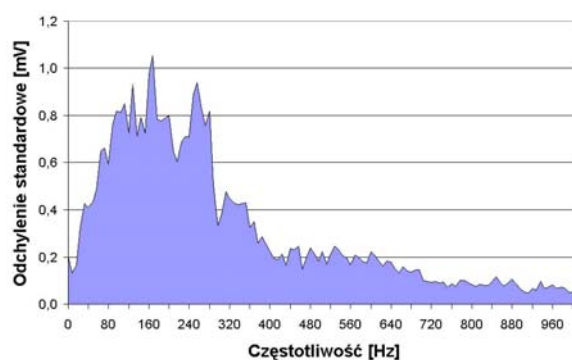
Wartość chwilowa poszczególnych harmonicznym widma sygnału EMG nie jest stała nawet w przypadku kiedy stan napięcia mięśni przedramienia się nie zmienia. Zjawisko to dobrze ilustrują rysunki 4.5 i 4.6. Na pierwszym z nich pokazano uśrednione widmo EMG (rozmiar próby, tj. ilość widm składowych wynosiła 25) rejestrowane podczas prostowania nadgarstka (patrz rysunek 4.4). O tym, że wartości chwilowe harmonicznym widma mogą się znacznie wahać, świadczy fakt, że odchylenie standardowe poszczególnych harmonicznym ma wartości zbliżone do wartości średnich tych harmonicznym. Duże fluktuacje widma stanowią utrudnienie w procesie rozpoznawania, co zostanie pokazane w rozdziale dotyczącym badań.



Rysunek 4.4 Przebiegi czasowe sygnału EMG rejestrowanego podczas prostowania nadgarstka (ułożenie A); wartość międzyszczytowa sygnału wynosi 2 mV; cały sygnał został podzielony na 25 okien, z każdego okna wyznaczono widmo sygnału.



Rysunek 4.5 Uśrednione widmo sygnału EMG (jeden kanał) zarejestrowanego podczas prostowania nadgarstka; ilość okien dla których wyznaczono wartość średnią harmonicznym widma wynosi 25.



Rysunek 4.6 Odchylenie standardowe wartości poszczególnych harmonicznym widma sygnału EMG (patrz rysunek 4.5)

5. Pomiar miopotencjałów

5.1 Zadanie układu pomiarowego

Podstawowym zadaniem układu pomiarowego jest umożliwienie rejestracji użytecznego sygnału EMG przy jednoczesnej eliminacji wszelkiego rodzaju zakłóceń [11] [13]. Jak wspomniano w rozdziale 4 poziom sygnałów EMG jest bardzo niski i może się zmieniać w zakresie od 1 μV do 100 mV, jednocześnie pomiar tego sygnału ten jest mocno zakłócony itp. napięciem indukowanym przez pole elektromagnetyczne pochodzące z linii energetycznych. A ich poziom może być niekiedy nawet o kilka rzędów wyższy od sygnału użytecznego. Dodatkową trudnością jest fakt, że mięśnie będące źródłem miopotencjałów wraz z tkanką tłuszczową stanowią z punktu widzenia elektrycznego układ o bardzo dużej i zmiennej w czasie impedancji wewnętrznej [4] [13]. Wszystko to razem powoduje, że pomiar EMG wymaga zastosowania specjalnych układów pomiarowych, które muszą sprostać specyficznym wymaganiom. Tego typu układy określa się wspólną nazwą jako wzmacniacze instrumentalne [11].

5.2 Wymagania stawiane wzmacniaczom instrumentalnym

Podstawowe wymagania stawiane wzmacniaczom instrumentalnym są następujące:

- wzmacniacz nie powinien w żaden sposób wpływać na monitorowaną aktywność fizjologiczną,
- mierzony sygnał nie powinien być zniekształcany,
- wzmacniacz powinien zapewnić, możliwie najlepszą, separację sygnału użytecznego od zakłóceń,
- wzmacniacz powinien chronić pacjenta przed ryzykiem porażenia prądem,
- wzmacniacz powinien być zabezpieczony przed ryzykiem uszkodzenia z powodu wyładowań elektrycznych napięciem o wysokim poziomie.

Rysunek 5.1 przedstawia typowe konfiguracje stosowane przy pomiarach biopotencjałów. Do pomiaru używa się trzech elektrod, dwie z nich służą do różnicowego wzmacniania sygnału natomiast trzecia jest elektrodą odniesienia. Sygnał wejściowy układu pomiarowego

składa się z następujących składników: (1) pożądanego sygnału bioelektrycznego, (2) niepożądanego sygnału bioelektrycznego, (3) zakłóceń zewnętrznych itp. pochodzących z linii energetycznych, (4) sygnału generowanego na styku powierzchnia skóry / elektroda oraz (5) szumów. Właściwie zaprojektowany układ pomiarowy powinien zapewnić znaczną redukcję sygnałów niepożądanych. Głównym zadaniem wzmacniacza instrumentalnego jest usunięcie z mierzonego sygnału bioelektrycznego zakłóceń zewnętrznych indukowanych poprzez pole elektromagnetyczne w ciele pacjenta. Użyteczny sygnał bioelektryczny występuje na wejściu wzmacniacza jako sygnał różnicowy. Zakłócenia zewnętrzne pochodzące ze środowiska, w którym przebywa pacjent występują na wejściu wzmacniacza jako sygnał sumacyjny, co wynika z faktu, że ich amplituda i faza są zbliżone do siebie na obu elektrodach wejściowych. Podstawową własnością dobrego wzmacniacza instrumentalnego jest zdolność do znacznego tłumienia sygnału sumacyjnego przy jednoczesnym odpowiednim wzmacnianiu sygnału różnicowego. Współczynnik tłumienia sygnału sumacyjnego $CMRR^2$, jest określany jako stosunek wzmocnienia wzmacniacza dla sygnału różnicowego do wzmocnienia tego wzmacniacza dla sygnału sumacyjnego i wyrażany w mierze liniowej lub logarytmicznej:

$$CMRR = \frac{K_{UR}}{K_{US}} \left[\frac{V}{V} \right] \quad (5.1)$$

$$CMRR = 20 \cdot \log_{10} \left(\frac{K_{UR}}{K_{US}} \right) [dB], \quad (5.2)$$

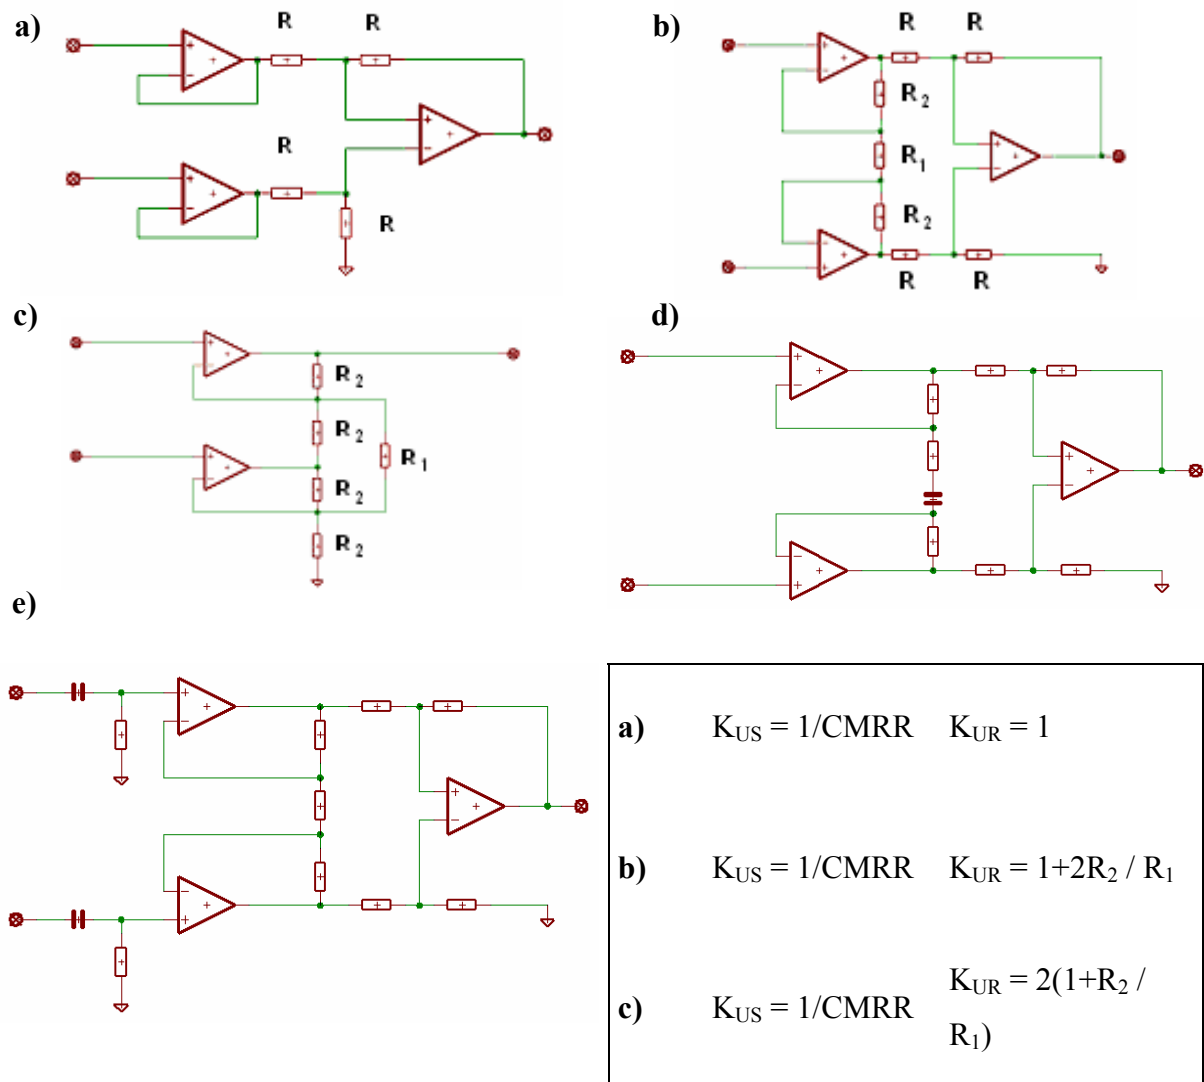
gdzie:

$CMRR$ - współczynnik tłumienia sygnału sumacyjnego,


K_{US} - wzmocnienie napięciowe wzmacniacza dla sygnału sumacyjnego,

K_{UR} - wzmocnienie napięciowe wzmacniacza dla sygnału różnicowego.

² $CMRR$ - ang. common mode rejection ratio.



Rysunek 5.1 Typowe konfiguracje układowe stosowane we wzmacniaczach instrumentalnych (a,b,c);
d,e – modyfikacja układu b) eliminująca problem dużego stałego potencjału na wejściu;
 K_{US} – wzmacnienie sumacyjne, K_{UR} – wzmacnienie różnicowe.



Rysunek 5.2 Idea pomiaru miopotencjałów przy użyciu wzmacniaczy różnicowych;
 S_1, S_2 – sygnał użyteczny, Z – zakłócenia

Wartość współczynnika CMRR całego układu pomiarowego zależy nie tylko od wartości tego współczynnika w zastosowanych wzmacniaczach, lecz także od impedancji Z_1 i Z_2 źródeł sygnałów mierzonych pomiędzy wejściami układu pomiarowego a elektrodą odniesienia. W przypadku idealnym, tj. kiedy $Z_1 = Z_2$ oraz wartość CMRR zastosowanych wzmacniaczy operacyjnych jest nieskończenie duża, układ pomiarowy wzmacnia tylko sygnał różnicowy (tj. sygnał użyteczny) jednocześnie całkowicie tłumiąc sygnał sumacyjny będący zakłóceniami. W rzeczywistości jednak impedancje źródeł sygnałów nie są równe a CMRR wzmacniaczy nie jest nieskończenie duży, dlatego też w sygnale wyjściowy oprócz wzmocnionego sygnału użytecznego będą także istnieć zakłócenia, jednak ich poziom może być znacznie zredukowany przy odpowiednim zaprojektowaniu układu pomiarowego. Amplituda sygnału wyjściowego określona jest następującą zależnością:

$$U_{wyj} = K_{UR} \cdot U_R + \frac{K_{UR} \cdot U_S}{CMRR} + K_{UR} \cdot U_S \cdot \left(1 - \frac{Z_{wej}}{Z_{wej} + Z_1 - Z_2}\right), \quad (5.3)$$

gdzie:

- U_{wyj} - amplituda sygnału wyjściowego,
- U_R - amplituda sygnału różnicowego (sygnału użytecznego),
- U_S - amplituda sygnału sumacyjnego (zakłócenia),
- Z_1 - impedancja źródła sygnału podłączonego do wejścia nieodwracającego,
- Z_2 - impedancja źródła sygnału podłączonego do wejścia odwracającego,
- Z_{wej} - impedancja wejściowa wzmacniacza,
- CMRR - współczynnik tłumienia sygnału sumacyjnego wyrażony w mierze liniowej,
- K_{US} - wzmocnienie napięciowe wzmacniacza dla sygnału sumacyjnego,
- K_{UR} - wzmocnienie napięciowe wzmacniacza dla sygnału różnicowego.

Z zależności (5.3) wyraźnie widać, że na przedostawanie się zakłóceń z wejścia wzmacniacza na wyjście wpływ mają dwa czynniki: skończona wartość CMRR wzmacniaczy oraz niezrównoważenie impedancji Z_1 i Z_2 . Aby zminimalizować poziom zakłóceń na wyjściu należy więc stosować wzmacniacze o jak największej wartości CMRR oraz bardzo dużej impedancji wejściowej Z_{wej} . Zaleca się, aby wartość CMRR była większa od 100 dB a impedancja wejściowa dla częstotliwości 50 Hz wynosiła 1 GΩ.

Poza sygnałem użytecznym oraz zakłóceniami zewnętrznymi w sygnale doprowadzanym do wejścia wzmacniacza instrumentalnego znajdują się dwie ważne składowe: stałe napięcie wytwarzane na styku elektroda / skóra oraz szумы. Poziom stałego napięcia może być nawet o kilka rzędów wyższy od poziomu sygnału EMG (patrz Rysunek 5.2), co oznacza, że niezbędne jest zastosowanie filtra górno przepustowego w celu usunięcia składowej stałej i tym samym niedopuszczenia do nasycenia się wzmacniacza. Szумы pojawiające się w sygnale mają charakter termiczny i powstają w każdym elemencie, przez który przechodzi sygnał, tj. na: impedancji wewnętrznej źródła sygnału oraz wzmacniaczu. Wartość skuteczna sygnału szumów powstająca na rezystancji wewnętrznej źródła sygnału dana jest wzorem:

$$U_{szum} = \sqrt{4 \cdot k \cdot T \cdot R_{\text{źródła}} \cdot B} \quad [\text{V}], \quad (5.4)$$

natomiast całkowite napięcie szumów dodające się do sygnału wejściowego dane jest zależnością:


$$U_{szum} = \sqrt{\int_{fd}^{fg} e_n^2 \cdot df + R_{\text{źródła}}^2 \cdot \int_{fd}^{fg} i_n^2 \cdot df + 4 \cdot k \cdot T \cdot R_{\text{źródła}} \cdot B}, \quad (5.5)$$

gdzie:

- T - temperatura absolutna pacjenta,
- K - stała Boltzmana,
- $R_{\text{źródła}}$ - rezystancja wewnętrzna źródła sygnału,
- e_n - współczynnik szumów napięciowych wzmacniacza,
- i_n - współczynnik szumów prądowych wzmacniacza,
- f_d, f_g - częstotliwość dolna / górna,
- B - pasmo częstotliwościowe, $B = f_g - f_d$.

Uzyskanie wysokiego współczynnika sygnał / szum wymaga więc zastosowania wzmacniaczy instrumentalnych o bardzo niskim szumie napięciowym i prądowym oraz ograniczenia pasma częstotliwościowego sygnału, który chcemy wzmocnić. Obecnie produkowane układy scalone mają wartość współczynnika e_n mniejsza od $10\text{nV} / \sqrt{\text{Hz}}$ oraz wartość współczynnika i_n mniejszą od $1\text{pA} / \sqrt{\text{Hz}}$. Oba te parametry zależą od częstotliwości a ich wartość maleje wprost proporcjonalnie wraz z jej kwadratem.

Jednym z najbardziej newralgicznych punktów podczas pomiaru sygnału EMG jest kontakt pomiędzy elektrodą a skórą. Zarówno stały potencjał generowany przez elektrodę jak i impedancja połączenia elektroda / skóra podlegają zmianie w wyniku wzajemnych ruchów jednego względem drugiego. Powoduje to, że w sygnale wejściowym pojawiają się dwa dodatkowe składniki, tzw. artefakty ruchowe. Pierwszy z nich może być wyeliminowany poprzez stosowanie filtru górno przepustowego lub specjalnych elektrod, w których to zjawisko jest ograniczone (itp. Ag/AgCl), problem elektrod będzie rozpatrywany w dalszej części pracy. Drugi składnik może być wyeliminowany dzięki zastosowaniu wzmacniacza o bardzo dużej impedancji wejściowej, jej duża wartość powoduje, że cały układ jest znacznie mniej wrażliwy na wahania impedancji wewnętrznej źródła sygnału.



Rysunek 5.2 Zakres częstotliwości i poziom sygnałów: EMG oraz generowanego przez elektrodę.


5.3 Elektrody EMG

Pomiar aktywności elektrycznej dowolnego organu człowieka wymaga, aby istniało elektryczne połączenie pomiędzy organem a układem pomiarowym. Ponieważ mięśnie są organami wewnętrznymi człowieka, bezpośredni pomiar ich aktywności elektrycznej wymaga zastosowania inwazyjnej metody pomiaru, tj. wprowadzenia elektrody do wnętrza ciała pacjenta. Jednakże sygnał EMG jest propagowany z mięśni do otaczającej tkanki, może więc być także mierzony na powierzchni skóry, w tym jednak przypadku należy pamiętać, że na jego charakter ma wpływ tkanka tłuszczowa znajdująca się pomiędzy mięśniem a skórą oraz inne mięśnie z których sygnał jest także propagowany. Zjawisko przesłuchu sygnału z innych


mięśni może być pożyteczne, jeśli chce się rejestrować sygnał z całej grupy mięśni jednocześnie, tak jest itp. w przypadku badań przedstawionych w tej pracy.

Istnieje wiele rodzajów elektrod [12] służących do pomiaru sygnałów bioelektrycznych, różnią się one budową mechaniczną oraz materiałem, z którego składa się część przewodząca prąd elektryczny. Dobór odpowiedniej elektrody zależy od jej przeznaczenia tj. czy ma to być elektroda do długotrwałego czy krótkotrwałego pomiaru, jednorazowa czy wielokrotnego użytku. W badaniach opisanych w tej pracy użyto jednorazowej elektrody Ag/AgCl stosowanej w pomiarach sygnałów EKG. Dalej zostanie przedstawiona budowa mechaniczna elektrody oraz jej parametry elektryczne.


Z punktu widzenia elektrycznego elektrody EMG są elementami nieliniowymi, których parametry mogą zmieniać się w czasie i zależą od stanu skóry, do której są przyczepione (itp. od tego czy skóra jest sucha czy wilgotna) oraz częstotliwości miopotencjałów. Aby uprościć sobie analizę zachowania elektrody konstruuje się jej przybliżony, liniowy model [12] zakładając, że mierzone sygnały mają małą amplitudę.



Rysunek 5.3 Model elektryczny elektrody EMG; E_{hc} – stałe napięcie wytwarzane na styku elektrody skóra, R_s - rezystancja szeregową materiału, z którego jest wykonana elektroda, R_d , C_d – rezystancja i pojemność złącza skóra / elektroda.



Rysunek 5.4 Zależność impedancji elektrody EMG od częstotliwości

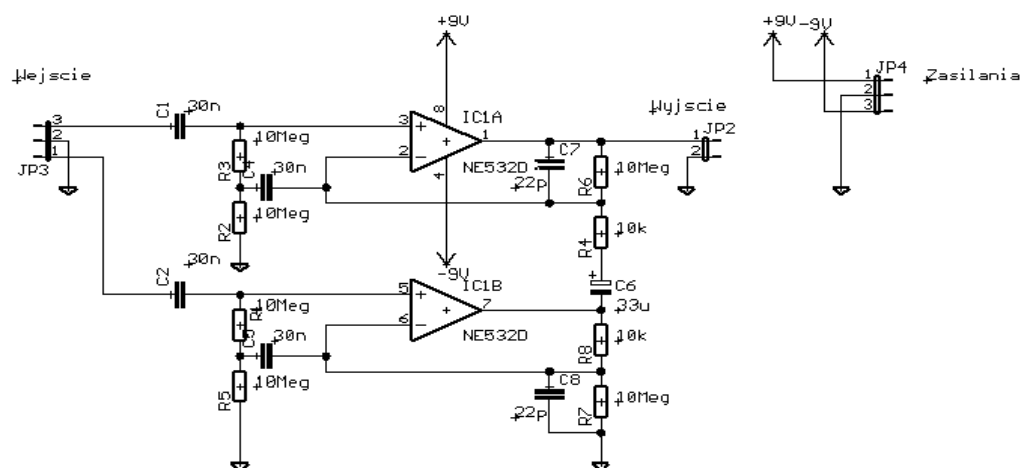


Rysunek 5.5 Budowa elektrody Ag / AgCl używanej w badaniach.

Rysunek 5.3 przedstawia model elektryczny elektrody Ag / AgCl używanej w badaniach, rezystor R_s reprezentuje rezystancję szeregową materiału z którego zbudowana jest elektroda, R_d i C_d to odpowiedni rezystancja i pojemność połączenia skóra / elektroda, natomiast E_{hc} to stałe napięcie generowane na styku skóra / elektroda, jego wartość wynosi 0.223 V. Impedancja elektrody nie jest stała i zależy od częstotliwości (patrz rysunek 5.4), dla niskich częstotliwości impedancja kondensatora C_d jest bardzo duża w porównaniu z R_d dlatego też impedancja całej elektrody wynosi $R_s + R_d$. Przy wzroście częstotliwości pojemność złącza skóra / elektroda zaczyna odgrywać coraz większą rolę i dla bardzo dużych częstotliwości impedancja elektrody spada do wartości R_s .

5.4 Projekt układu pomiarowego

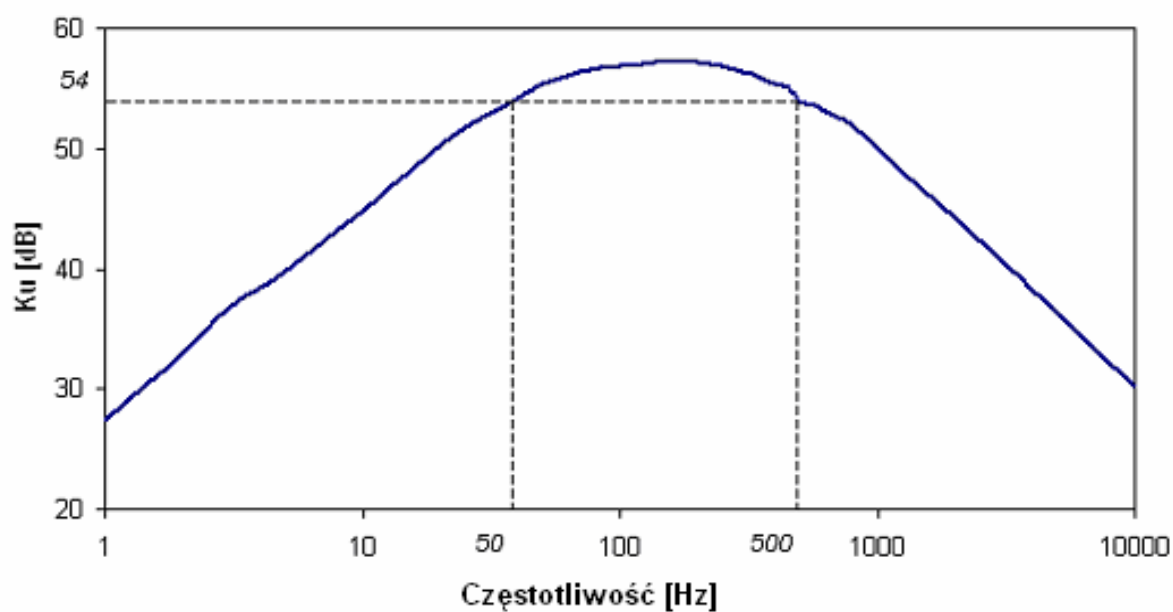
W trakcie prac nad budową aktywnej elektrody EMG zaprojektowano i wykonano dwa układy wzmacniaczy pomiarowych. Pierwszy projekt został wykonany z użyciem wzmacniaczy operacyjnych, połączonych z elementami dyskretnymi w technologii SMD. Ponieważ parametry zbudowanego układu okazały się nie spełniać wymagań stawianych wzmacniaczom miopotencjałów, zdecydowano się na budowę kolejnego układu w oparciu o wzmacniacz instrumentalny. Dalej zostaną przedstawione projekty obu zbudowanych układów pomiarowych.



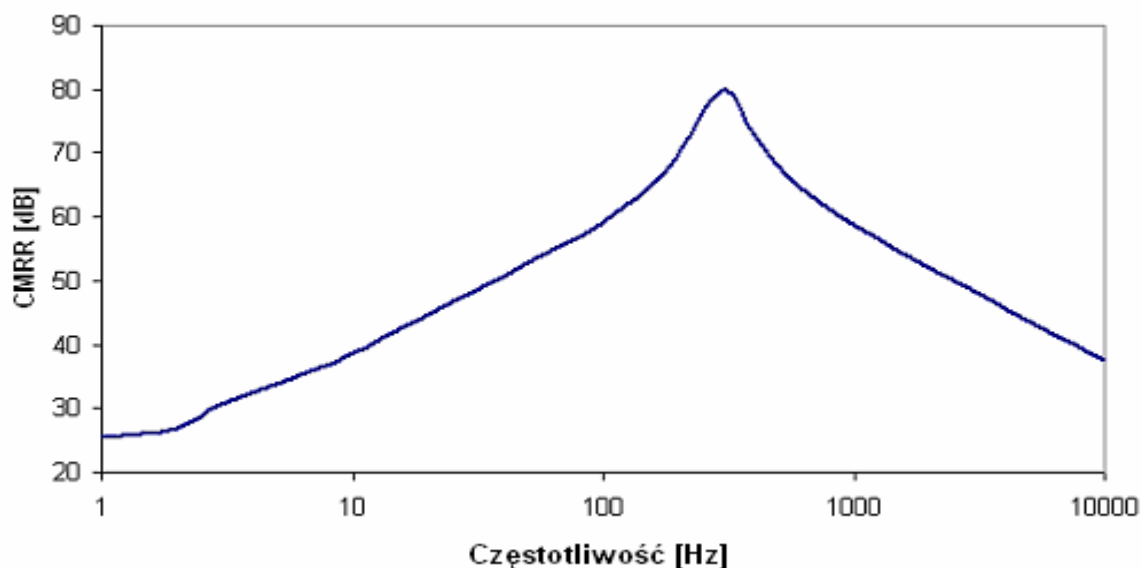
Rysunek 5.6 Schemat elektryczny układu pomiarowego zbudowanego w oparciu o wzmacniacze operacyjne.

Impedancja wejściowa	$> 10 \text{ M}\Omega$
Wzmocnienie	1000 V/V, 60 dB
CMRR	$> 50 \text{ dB}$
Napięcie zasilania	$\pm 9\text{V}$
Dolna częstotliwość graniczna	50 Hz
Górna częstotliwość graniczna	500 Hz

Tabela 5.1 Podstawowe parametry elektryczne wzmacniacza z rysunku 5.6

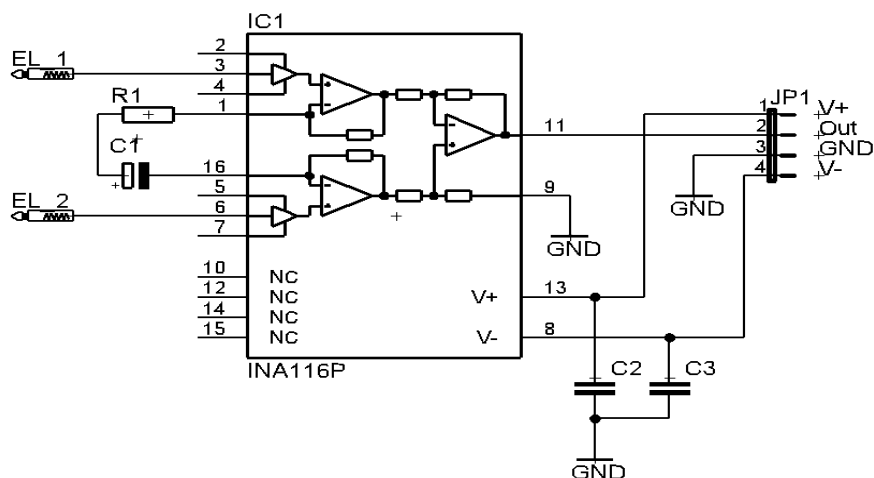


Rysunek 5.8 Zależność wzmocnienia różnicowego wzmacniacza z rysunku 5.6 w funkcji częstotliwości.




Rysunek 5.10 Zależność współczynnika CMRR wzmacniacza z rysunku 5.6 w funkcji częstotliwości.

Współczynnik CMRR układu pomiarowego wykonanego z użyciem dyskretnych wzmacniaczy operacyjnych jest dużo mniejszy od zalecanej wartości 100 dB i na krańcach pasma przenoszenia (50Hz, 500Hz) spada do wartości około 50 dB. Także impedancja wejściowa wzmacniacza jest dużo mniejsza do zalecanej wartości $1\text{G}\Omega$ i wynosi $10\text{M}\Omega$. Ponieważ oba wymienione parametry pierwszego układu pomiarowego daleko nie spełniały wymagań stawianych wzmacniaczom biosygnałów zdecydowano się na budowę kolejnego układu pomiarowego, tym razem wykorzystując wzmacniacz instrumentalny INA116, którego parametry spełniają wszystkie stawiane wymagania.




Rysunek 5.11 Schemat elektryczny układu pomiarowego zbudowanego w oparciu o wzmacniacz instrumentalny.




Rysunek 5.12 Odwód drukowany układu pomiarowego przedstawionego na rysunku 5.6

Impedancja wejściowa	$> 10^{15} \Omega$
Wzmocnienie	1000 V/V, 60 dB
CMRR	> 90 dB
Napięcie zasilania	$\pm 9V$
Dolna częstotliwość graniczna	< 1 Hz
Górna częstotliwość graniczna	> 10 kHz


Tabela 5.2 Podstawowe parametry elektryczne wzmacniacza z rysunku 5.11



Rysunek 5.13 Zależność wzmocnienia różnicowego wzmacniacza z rysunku 5.11 w funkcji częstotliwości.



Rysunek 5.13 Zależność wzmocnienia sumacyjnego wzmacniacza z rysunku 5.11 w funkcji częstotliwości.




Rysunek 5.14 Zależność współczynnika CMRR wzmacniacza z rysunku 5.11 w funkcji częstotliwości.

6. Próbkowanie sygnału

Jak pokazano wcześniej sygnały EMG są to ciągłe sygnały napięciowe zarówno w dziedzinie czasu jak i wartości które mogą przyjąć. Jednakże, aby ich analiza przy pomocy komputera była możliwa konieczne jest zmiana reprezentacji rejestrowanego sygnału z ciągłej na dyskretną – cyfrową. Zmiana taka nie może być dokonana w dowolny sposób, powinna ona zagwarantować nam to, że reprezentacja cyfrowa będzie zawierać całą informację, która jest niesiona w pierwotnym sygnale, ewentualnie, że utrata informacji będzie nieznaczna i do zaakceptowania.

6.1 Co to jest próbkowanie?

Próbkowanie sygnału jest procesem polegającym na pomiarze wartości chwilowej próbkowanego sygnału w równych, ściśle określonych chwilach czasowych i zapamiętaniu ich w postaci cyfrowej. Wynikiem procesu próbkowania jest ciąg liczb, których kolejne wartości odpowiadają kolejnym wartościom chwilowym pierwotnego sygnału.




Rysunek 6.3 Cyfrowa reprezentacja sygnału ciągłego próbkowanego z częstotliwością 1 Hz

6.2 Częstotliwość próbkowania


Jednym z najważniejszych parametrów procesu próbkowania jest częstotliwość próbkowania tj. częstotliwość, z jaką następuje pomiar kolejnych wartości sygnału.

Jej wartość ściśle zależy od charakteru próbkowanego sygnału i nie może być dobrana całkowicie dowolnie, powinna ona być na tyle duża, aby było możliwe odtworzenie pierwotnego sygnału na podstawie jego reprezentacji cyfrowej. Poniżej przedstawiono rysunki, które w sposób intuicyjny starają się wytłumaczyć, jaka jest najmniejsza możliwa do przyjęcia częstotliwość próbkowania. W przykładzie użyto funkcji sinus, ponieważ ma ona szczególne znaczenie przy wyznaczaniu trygonometrycznej transformaty Fouriera, co zostanie pokazana w dalszej części pracy.




Rysunek 6.4 Sygnał sinusoidalnie zmienny o częstotliwości 1 Hz
próbkowany z częstotliwością 10 Hz

Rysunek 6.4 przedstawia sygnał sinusoidalnie zmienny o częstotliwości 1 Hz próbkowany z częstotliwością 10 Hz. Jak łatwo można zauważyć kolejne próbki są blisko siebie dzięki czemu odtworzenie pierwotnego sygnału może być dokonane poprzez proste łączenie kolejnych próbek odcinkami prostej.



Rysunek 6.5 Sygnał sinusoidalnie zmienny o częstotliwości 1 Hz
próbkowany z częstotliwością 2 Hz

Rysunek 6.5 przedstawia ten sam sygnał, lecz tym razem próbkowany z częstotliwością 2 Hz. Łączenie kolejnych próbek odcinkami prostej powoduje, że odtworzony sygnał nie przypomina sygnału pierwotnego. Jeśli jednak założyć, że wystarczającym jest możliwość wyliczenia najmniejszej częstotliwości sygnału próbkowanego pasującej do próbek to częstotliwością tą jest właśnie 1 Hz. Oznacza to, że dalej jesteśmy w stanie stwierdzić jak wyglądał sygnał pierwotny.



Rysunek 6.6 Sygnał sinusoidalnie zmienny o częstotliwości 1 Hz próbkowany z częstotliwością $4/3$ Hz, ten sam ciąg próbek uzyskamy, jeśli będziemy próbkować sygnał o częstotliwości $1/3$ Hz

Efekt zbyt małej częstotliwości próbkowania można zobaczyć na rysunku 6.4. Oryginalny sygnał o częstotliwości 1 Hz został spróbkowany z częstotliwością $4/3$ Hz. Wynikowy ciąg próbek nie reprezentuje już sygnału pierwotnego, gdyż pasuje on zarówno do sygnału 1 Hz jak i $1/3$ Hz. Jeśli założyć, że chcąc odtworzyć sygnał oryginalny zawsze wybieramy najmniejszą częstotliwość, do jakiej pasują próbki to rezultatem jest sygnał sinusoidalnie zmienny o częstotliwości $1/3$ Hz a więc inny od sygnału pierwotnego.

6.3 Kryterium Nyquista

Rysunki przedstawione w poprzednim paragrafie pokazują, że aby możliwe było odtworzenie pierwotnego sygnału, *częstotliwość próbkowania nie może być mniejsza niż dwukrotna częstotliwość sygnału próbkowanego*. Mimo, że podane przykłady pokazywały jedynie sygnały sinusoidalnie zmiennie, to kryterium Nyquista jest prawdziwe także dla innych sygnałów, co zostanie dokładniej wyjaśnione w następnym paragrafie dotyczącym

transformaty Fouriera. Teoretyczne wyprowadzenie kryterium Nyquista można znaleźć między innymi w [1].

6.4 Transformata Fouriera

Można pokazać, że każdy okresowy i ciągły sygnał $x(t)$ daje się przedstawić jako nieskończona ważona suma sygnałów sinusoidalnie zmiennych. Zbiór takich sinusoid (zwanych też harmonicznymi) jest nazywany trygonometrycznym szeregiem Fouriera lub widmem sygnału. Sygnał pierwotny może być odtworzony z trygonometrycznego szeregu Fouriera w następujący sposób:

$$x(t) = A + \sum_{n=1}^{\infty} [B_n \cdot \sin(\omega_n \cdot t) + C_n \cdot \cos(\omega_n \cdot t)], \quad (6.1)$$

gdzie:

- A – wartość średnia sygnału za okres,
- B_n – wartość współczynnika wagowego dla n -tego składnika sinusoidalnie zmiennego,
- C_n – wartość współczynnika wagowego dla n -tego składnika kosinusoidalnie zmiennego,
- ω_n – częstość n -tych składników szeregu.

Wartość współczynników A , B_n , oraz C_n można wyznaczyć z następujących zależności:

$$\omega_n = n \cdot \frac{2\pi}{T}, \quad n \in N^+, \quad (6.2)$$

$$A = \frac{1}{T} \int_t^{t+T} x(t) dt, \quad (6.3)$$


$$B_n = \frac{1}{2 \cdot T} \int_t^{t+T} x(t) \cdot \sin(\omega_n \cdot t) dt, \quad (6.4)$$

$$C_n = \frac{1}{2 \cdot T} \int_t^{t+T} x(t) \cdot \cos(\omega_n \cdot t) dt, \quad (6.5)$$

gdzie:

- T – okres sygnału próbkowanego.

Z matematycznego punktu widzenia transformaty Fouriera może być traktowana jako rzutowanie wektora $x(t)$ należącego do nieskończenie wymiarowej przestrzeni $L^2(0, T)$ funkcji całkowalnych z kwadratem na kolejne wektory bazowe tej przestrzeni. Więcej informacji na temat matematyczny aspektów transformaty Fouriera sygnałów okresowych i nieokresowych, deterministycznych i stochastycznych można znaleźć w [1].




Rysunek 6.7 Przykład rozkładu funkcji okresowej i ciągłej na składowe sinusoidalnie zmienne przy użyciu transformaty Fouriera.

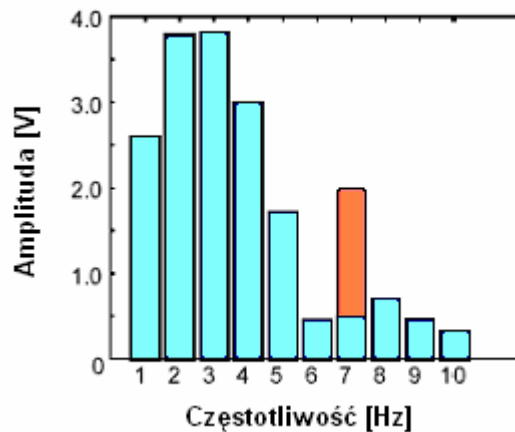
6.5 Efekt mieszania częstotliwości

Zgodnie z kryterium Nyquista najmniejsza częstotliwość próbkowania umożliwiająca jeszcze odtworzenie sygnału pierwotnego musi być większa od dwukrotnej częstotliwości

sygnału próbkowanego. Jeśli jeszcze do tego uwzględnić fakt, że każdy sygnał okresowy i ciągły można rozłożyć na szereg trygonometryczny to kryterium Nyquista w odniesieniu do sygnałów nie będących funkcjami sinusoidalnie zmiennymi można zdefiniować w analogiczny sposób. Mianowicie, częstotliwość próbkowania sygnału ciągłego i okresowego powinna być większa od dwukrotnej częstotliwości najwyższej harmonicznej zawartej w tym sygnale. Można sobie zadać pytanie, co się dzieje z wyznaczonym widmem sygnału, kiedy częstotliwość próbkowania jest za mała, tj. kiedy kryterium Nyquista nie jest spełnione dla wszystkich harmonicznych znajdujących się w tym sygnale.



Rysunek 6.6 Widmo sygnału, w którym częstotliwość najwyższej harmonicznej wynosi 13 Hz



Rysunek 6.7 Efekt mieszania częstotliwości wynikający ze zbyt małej częstotliwości próbkowania, pierwotna częstotliwość 13 Hz występuje w widmie jako harmoniczna 7 Hz.

Na rysunku 6.6 przedstawiono rzeczywiste widmo pewnego sygnału w którym częstotliwość najwyższej harmonicznej wynosi 13 Hz. Częstotliwość próbkowania tego sygnału wynosi 20 Hz, co oznacza, że kryterium Nyquista jest spełnione dla harmonicznych o częstotliwościach nie większych od 10 Hz. Rysunek 6.7 przedstawia widmo tego sygnału uzyskane z transformaty Fouriera spróbowanego sygnału, harmoniczna o częstotliwości 13 Hz nie występuje na prawidłowej pozycji lecz zakłóca wartość harmonicznej 7Hz. Efekt ten określany jest jako mieszanie częstotliwości (ang. aliasing) i jest niepożądany. Częstotliwość f_{alias} , na której pojawi się mylnie odwzorowana harmoniczna, dla której nie jest spełnione kryterium Nyquista, można wyznaczyć z następującej zależności:

$$f_{\text{alias}} = | \text{najbliższa całkowita wielokrotność częstotliwości próbkowania} - \text{częstotliwość składowej analizowanej} |.$$

7. Rozpoznawanie stanu dłoni na podstawie EMG

7.1 Podstawy rozpoznawania obiektów

Rozpoznawanie obiektów [2] (zjawisk, procesów, sygnałów, sytuacji, itp.) jest to zdolność do przypisania im konkretnego znaczenia (klasy) na podstawie pewnych charakterystycznych właściwości (cech). Jednym ze sposobów poradzenia sobie z problemem rozpoznawania jest tzw. podejście decyzyjno-teoretyczne³. Jego cechą charakterystyczną jest to, że rozpoznawany obiekt jest reprezentowany wektorem liczb otrzymanych itp. przez próbkowanie przebiegu czasowego, skanowanie kształtu, czy wprost z pomiaru lub obserwacji typowych jego cech, a decyzja zaliczająca obiekt do klasy wynika z przetworzenia tych liczb według odpowiedniego algorytmu, zgodnego z apriorycznymi regułami wiążącymi klasy i liczbowe charakterystyki obiektów. Niezależnie od natury podmiotu rozpoznawania będziemy zakładać, iż można mu przypisać pewne mierzalne atrybuty, tj. wielkości poddające się naszej obserwacji lub pomiarowi nazywane cechami. Wartości cech, wspólnie ujęte w uporządkowany sposób, tworzą tzw. wektor wartości cech:

$$x = [x^{(1)}, x^{(2)}, \dots, x^{(d)}], \quad (7.1)$$


i stanowią w zadaniu rozpoznawania źródło informacji o obiekcie. Zbiór wszystkich wartości, jakie mogą przyjmować cechy obiektów w rozpatrywanym zadaniu nazywa się przestrzenią cech i oznacza się przez X .

Z określeniem i uzyskaniem wektora x wiążą się dwa zadania stowarzyszone nierozłącznie z problemem rozpoznawania. Pierwszy z nich dotyczy technicznej kwestii recepcji informacji opisującej obiekt oraz metodologii w podejściu do niej. W większości przypadków ogranicza się ono do określenia procedur i technik pomiarowych, gdyż zazwyczaj mamy do czynienia z cechami przyjmującymi wprost wartości liczbowe (wzrost, waga, itp.). Drugie z zadań związanych z rozpoznawaniem to tak zwana selekcja cech. Jej zasadność i potrzeba wynika z faktu iż realne obiekty są opisywane na ogół dużą ilością cech, nierzadko sięgającą dziesiątek i setek tysięcy. Rozsądnie jest zatem założyć, że jedynie niektóre z nich, odpowiedni wybrane, są ujęte w wektorze (7.1). Wybór taki, zwany właśnie selekcją cech może być dokonywany na różnych zasadach i wynikać z rozmaitych przesłanek. Istotnym kryterium

³ ang, decision-theoretical pattern recognition

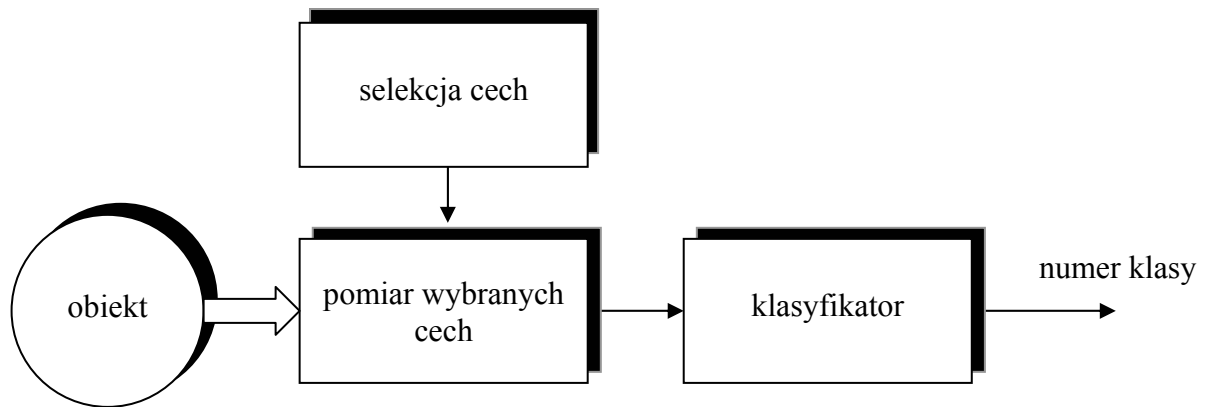
wyboru cech może być łatwość pomiaru czy obserwacji jej wartości, ogólnie koszt związany z jej uzyskiwaniem, przy czym koszt ten nie zawsze musi być rozumiany dosłownie.

Analizując kryteria selekcji cech należy odnieść je do celu, w jakim wartości wybranych cech będą obserwowane czy mierzone. Z punktu widzenia rozpoznawania, bo takie jest ich przeznaczenie przydatność cech nie jest na ogół jednakowa. Zjawisko, o którym mowa, ilustruje rysunek 7.1, gdzie przedstawiono przykład zadania rozpoznawania z dwoma klasami. Obiekty są opisane dwoma cechami, mogącymi przyjmować wartości z zacienionych obszarów, zależnie od klasy do której należą. Jeśli zadanie selekcji polegałoby na wyborze jednej z cech, to łatwo zauważyć, iż przydatność cechy pierwszej tj. jej siła różnicująca klasy jest zdecydowanie większa niż cechy drugiej. Wynika to z faktu, że przedziały zmienności wartości cechy pierwszej są dla obu klas rozłączne, co oznacza dalej, że cecha ta jednoznacznie różnicuje klasy. Tej własności nie ma cecha druga, dla której przedziały zmienności w obu klasach nachodzą na siebie. Wniosek jest oczywisty: umiejętne wykorzystanie cechy pierwszej prowadzi do bezbłędneho rozpoznawania podczas gdy wykorzystanie tylko drugiej cechy oznacza pojawienie się błędu w rozpoznawaniu.



Rysunek 8.1 Ilustracja selekcji cech; duże liczby 1,2 oznaczają numer klasy

Należy zauważyć, że zadanie selekcji cech nie jest problemem błahym. Nie istnieje żaden algorytm (poza zawsze istniejącym polegającym na przeglądzie zupełnym), który umożliwiłby wybór optymalnego podzbioru d cech z całego zbioru cech o liczebności N , tak aby jakość rozpoznawania nie była gorsza od tej uzyskanej z użyciem całego zbioru cech.



Rysunek 7.2 Schemat systemu rozpoznawania

Przejdźmy teraz do najważniejszego zadania procesu rozpoznawania jakim jest klasyfikacja. Przyjmijmy, że mamy do czynienia z zadaniem rozpoznawania, w którym M klas zostało ponumerowanych kolejnymi liczbami naturalnymi. Tak więc:

$$M = \{1, 2, \dots, M\}, \quad (7.2)$$


jest zbiorem numerów klas, a zadanie klasyfikacji polega na przypisaniu rozpoznawanemu obiektowi na podstawie znajomości wartości wybranych cech (7.1) numeru klasy $i \in M$. Sposób podejmowania decyzji o klasie, przepis według którego odbywa się przyporządkowanie rozpoznawanemu obiektowi numeru klasy jest nazywany algorytmem klasyfikacji i będzie oznaczany grecką literą ψ . Z kolei realizacja algorytmu ψ (itp. techniczne urządzenie lub program komputerowy) nosi nazwę klasyfikatora lub urządzenia rozpoznającego.

Algorytm klasyfikacji ψ przypisuje każdemu wektorowi zmierzonych cech $x \in X$ numeru klasy $i \in M$, co można zapisać $\psi(x) = i$. Innymi słowy algorytm ψ odwzorowuje przestrzeń cech w zbiór numerów klas:

$$\psi : X \rightarrow M, \quad (7.3)$$

lub równoważnie generuje rozkład przestrzeni cech na tak zwane obszary decyzyjne

$$D_x^{(i)} = \{x \in X : \psi(x) = i\}, \quad i \in M, \quad (7.4)$$



Rysunek 7.3 Przykład obszarów decyzyjnych algorytmu rozpoznawania, ilość klas wynosi 3

7.2 Bayesowska teoria decyzji

Podstawą Bayesowskiej teorii decyzji jest założenie, że zadanie rozpoznawania można przedstawić w postaci modelu statystycznego w którym wektor wartości cech opisujących rozpoznawany obiekt $x = (x^{(1)}, x^{(2)}, \dots, x^{(d)})$ oraz numer klasy j , do której on należy stanowią realizację pary zmiennych losowych (X, J) . Zmienna losowa J , przyjmująca wartości ze zbioru numerów klas $M = \{1, 2, \dots, M\}$ jest typu dyskretnego (skokowego), natomiast przestrzeń cech $X \in \mathbb{R}^d$ jest ciągła.

Rozkład zmiennej losowej jest scharakteryzowany prawdopodobieństwami :

$$P(J = j) = p_j, j \in M, \quad (7.5)$$

które będą nazywane prawdopodobieństwami *a priori* klas. Prawdopodobieństwo to mówi nam jak często obiekty należące do klas j występują w ogólnej liczbie obiektów. Zmienna losowa X ma dla każdej wartości $j \in M$ funkcje gęstości prawdopodobieństwa:

$$f(x / j) = f_j(x), x \in X, \quad (7.6)$$

która jest nazywana warunkową gęstością cech w klasie. Bezwarunkowa gęstość prawdopodobieństwa zmiennej X określona jako

$$f(x) = \sum_{j \in M} p_j f_j(x), \quad (7.7)$$

jest nieujemna dla wszystkich $x \in X$.

Z zadaniem rozpoznawania związana jest jeszcze jedna funkcja dwóch argumentów określona następująco:

$$0 \leq L(i, j) < \infty, i, j \in M. \quad (7.8)$$

Funkcja (7.8) jest nazywana funkcją strat a jej wartość jest interpretowana jako stratę, która jest ponoszona, gdy obiekt z klasy j został zaliczony do klasy i . Funkcja strat ma w zadaniu rozpoznawania bardzo konkretny aspekt, gdyż wiąże się z wymierną oceną skutków podjętej decyzji. W przypadku trafego rozpoznania zazwyczaj strata nie występuje i dlatego $L(j, j) = 0$ dla wszystkich $j \in M$. Gdy $i \neq j$, tzn. gdy podejmujemy błędną decyzję wartość funkcji strat jest określona ujemnymi konsekwencjami popełnionego błędu. Jeżeli następstwo błędnej klasyfikacji jest niewymierne, trudne do oszacowania, lub wynika wyłącznie z samego faktu popełnionego błędu a nieistotny jest jego rodzaj, wtedy wygodnie jest przyjąć tzw. zerojedynkową funkcję strat:

$$L(i, j) = \begin{cases} 0, & \text{gdy } i = j, \\ 1, & \text{gdy } i \neq j. \end{cases} \quad (7.9)$$

Ponieważ wartość zmiennej cech obiektu x jest realizacją zmiennej losowej to wynik rozpoznawani, czyli numer klasy i wskazany przez algorytm rozpoznawania ψ jest także realizacją zmiennej losowej. Tak więc $I = \psi(X)$ i na tej podstawie możemy określić następujące prawdopodobieństwo warunkowe:

$$q(i / j) = P(I = i / J = j) = \int_{D_x^{(i)}} f_j(x) dx, \quad (7.10)$$

oznacza prawdopodobieństwo zdarzenia, że wartość cech obiektu z klasy j -tej „wpadną” do $D_x^{(i)}$, czyli do i -tego obszaru decyzyjnego algorytmu ψ lub równoważnie, że algorytm ψ

zaliczy obiekt z klasy j-tej do klasy i-tej (tj. mając obiekt z klasy j-tej popełni błąd w rozpoznawaniu i zaliczy ją do klasy i-tej). W szczególności $q(j / j)$ jest prawdopodobieństwem poprawnej klasyfikacji przez algorytm ψ obiektu z klasy j-tej, a

$$P_C[\psi] = \sum_{j \in M} p_j q(j / j) = \sum_{j \in M} p_j \int_{D_X^{(j)}} f_j(x) dx, \quad (7.11)$$

oznacza średnie prawdopodobieństwo poprawnej klasyfikacji algorytmu rozpoznawania ψ . Prawdopodobieństwo błędnej klasyfikacji równa się:

$$P_E[\psi] = 1 - P_C[\psi]. \quad (7.12)$$

Wartość oczekiwana funkcji strat określona jest następująco:

$$R[\psi] = E[L(I, J)] = E[L(\psi(x), J)], \quad (7.13)$$

I, J x, J

mówi nam o ryzyku średnim reguły decyzyjnej (algorytmu rozpoznawania) ψ , tj. o średniej wartości kosztów jakie będą ponoszone w przypadku użycia ψ . Rozpisując ryzyko otrzymujemy następujący związek:

$$R[\psi] = E[L(\psi(x), J)] = \sum_{j \in M} p_j \sum_{i \in M} L(i, j) q(i / j), \quad (7.14)$$

w którym wyrażnie widać zależność wartości ryzyka od algorytmu rozpoznawania poprzez jego obszary decyzyjne lub równoważnie, poprzez prawdopodobieństwa $q(i / j)$. W przypadku zerojedynkowej funkcji strat wartość $R[\psi]$ równa się prawdopodobieństwu błędnej klasyfikacji, tj.

$$R[\psi] = P_E[\psi]. \quad (7.15)$$

Wyznaczenia optymalnej Bayesowskiej reguły decyzyjnej polega określeniu dla każdej obserwacji cech $x \in X$ takiej klasy dla której występuje minimalizacja $R[\psi]$, co dla

zerojedynkowej funkcji strat równoważne jest wyborowi klasy i dla której $p_i(x)$ jest maksymalne, tj.

$$\psi^*(x) = i, \text{ gdy } p_i(x) = \max_{k \in M} p_k(x), \quad (7.16)$$

gdzie:


ψ^* - optymalny Bayesowski algorytm rozpoznawania.

Sens algorytmu jest intuicyjnie oczywisty: rozpoznawany obiekt należy zaliczyć do tej klasy, która – dla zaobserwowanych wartości cech x - jest najbardziej prawdopodobna.

W przypadku dowolnej postaci funkcji strat algorytm optymalny przyjmuje postać:

$$\psi^*(x) = i, \text{ gdy } \sum_{j \in M} L(i, j) p_j f_j(x) = \min_{k \in M} \sum_{j \in M} L(k, j) p_j f_j(x), \quad (7.17)$$

tj. decyzją algorytmu jest ta klasa dla której średni koszt $\sum_{j \in M} L(i, j) p_j f_j(x)$ związany z zaklasyfikowaniem obiektu z klasy j do innych klas jest minimalny.



Rysunek 7.4 Prawdopodobieństwo błędnej klasyfikacji optymalnego algorytmu Bayesowskiego ψ^* ; przesunięcie granicy decyzyjnej w inne położenie spowoduje wzrost błędu.

7.3 Algorytm rozpoznawania k-NN

Algorytm klasyfikacji k najbliższych sąsiadów⁴ oznaczany krótko k-NN jest przykładem klasyfikatora nieparametrycznego korzystającego ze zbioru uczącego tj. zbioru poprawnie rozpoznanych obiektów:

$$S = \{(x_1, j_1), (x_2, j_2), \dots, (x_N, j_N)\}, \quad (7.18)$$

gdzie N jest liczebnością zbioru niezależnych obiektów, z których każdy opisany jest wektorem wartości cech (x_i) oraz numerem klasy (j_i). Elementy zbioru (7.18) nazywa się obiektami uczącymi. Podzbiór zbioru S utworzony z obiektów uczących należących do klasy j-tej będzie oznaczany jako:

$$S_j = \{(x_i, j_i): i = 1, 2, \dots, N, j_i = j, j \in M\}, \quad (7.19)$$

i założymy, że jego elementy pochodzą z populacji o warunkowej gęstości prawdopodobieństwa $f_j(x)$. Załóżmy, że k_j obiektów uczących ze zbioru S_j znalazło się w pewnym obszarze $A \in X$. Tak więc, prawdopodobieństwo zdarzenia, że wartość cech obiektu z j-tej klasy wpadną do A, które jest równe

$$P = \int_A f_j(x) dx, \quad (7.20)$$

można oszacować częstością:

$$\hat{P} = \frac{k_j}{N_j}, \quad (7.21)$$

gdzie:

k_j – ilość obiektów ze zbioru uczącego S należących do klasy j

i znajdujących się w obszarze A,

N_j – ilość wszystkich obiektów ze zbioru uczącego S należących do klasy j.

Zgodnie z regułą Bayesa (dla zerojedynkowej funkcji start) decyzją algorytmu klasyfikującego powinien być numer tej klasy dla której prawdopodobieństwo P w obszarze A jest największe, co dla klasyfikatora k-NN sprowadza się do reguły:




⁴ ang. k – nearest neighbours

$$\psi_S^{(k-NN)}(x) = i, \text{ gdy } k_i = \max_{j \in M} k_j. \quad (7.22)$$

Innymi słowy algorytm k-NN zalicza rozpoznawany obiekt do tej klasy, która jest najliczniej reprezentowana wśród k jego najbliższych sąsiadów ze zbioru uczącego S.

7.4 Problem rozpoznawania stanu dłoni

Rysunek 7.2 przedstawia ogólny schemat procesu rozpoznawania. W przypadku problemu rozpoznawania stanu dłoni obiektem jest przedramię człowieka wraz z dłonią, wybranymi cechami są przetworzone parametry częstotliwościowe i statystyczne sygnału EMG rejestrowanego z mięśni przedramienia natomiast klasami do których może należeć obiekt są wybrane stany dłoni (lub też wybrane konfiguracje stanów napięcia i rozluźnienia mięśni przedramienia odpowiadające wspomnianym stanom dłoni). Zadaniem klasyfikatora jest określenie aktualnego stanu dłoni człowieka na podstawie aktywności elektrycznej mięśni przedramienia, reprezentowanej poprzez ustalony wektor cech. Wektor cech nie jest ustalony z góry, określenie jego postaci jest częścią badań przedstawionych w tej pracy dlatego też będzie on szczegółowo opisany w rozdziale 9 gdzie przedstawiono wyniki badań.

Numer klasy	Stan dłoni jako obiekt rozpoznawania	Opis
1		Dłoń swobodna , mięśnie przedramienia nie napięte.
2		Dłoń wyprostowana w nadgarstku , palce wyprostowane i połączone, ułożone prostopadłe do powierzchni przedramienia.
3		Dłoń zgięta w nadgarstku , palce wyprostowane i połączone, ułożone prostopadłe do powierzchni przedramienia.




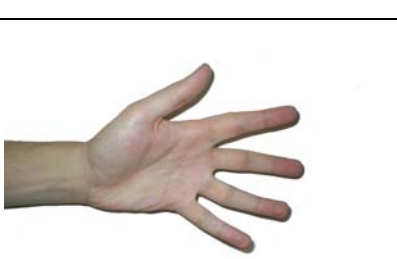


4		Dłoń odchylona w kierunku kości promieniowej , palce wyprostowane i połączone, ułożone równolegle do powierzchni przedramienia.
5		Dłoń odchylona w kierunku kości łokciowej , palce wyprostowane i połączone, ułożone równolegle do powierzchni przedramienia.
6		Palce dłoni zgięte tworzą pięść , dłoń w nadgarstku w stanie neutralnym.
7		Palce dłoni wyprostowane i rozsunięte daleko od siebie, dłoń w nadgarstku w stanie neutralnym.
8		Dłoń wraz z przedramieniem wykonuje obrót w kierunku kciuka, palce wyprostowane i połączone razem – supinacja przedramienia.
9		Dłoń wraz z przedramieniem wykonuje obrót w kierunku przeciwnym do kciuka, palce wyprostowane i połączone razem – pronacja przedramienia.

Tabela 7.1 Wybrane stany dłoni jako obiekty rozpoznawania;
pogrubieniem zaznaczono opisową nazwę klasy

7.5 Ocena jakości rozpoznawania

Jak wspomniano już wielokrotnie wcześniej, podstawą oceny jakości informacji ekstrahowanych z EMG (wektora cech) jest błąd rozpoznawania wyszczególniony stanów dłoni. Aby ocena ta była wiarygodna musi być wykonana na innym (niezależnym) zbiorze

danych od tego, używanego przez algorytm k-NN jako źródło informacji o rozkładzie prawdopodobieństwa cech w klasach. Zbiór ten określany jest nazwą zbioru testującego, ponieważ jego zadaniem jest ocena jakości algorytmu klasyfikacji z użyciem obiektów „z życia”, tj. takimi z którymi nie zetkną się podczas nauki. Podstawą oceny jakości rozpoznawania w tej pracy, będzie błąd ogólny popełniany przez algorytm klasyfikacji na zbiorze testującym, tj. procentowa ilość popełnionych pomyłek, czyli przypadków zaklasyfikowania obiektu do klasy innej niż rzeczywista. Oprócz błędu ogólnego będą podawane także błędy cząstkowe odnoszące się tylko do pojedynczych klas. Błędy cząstkowe niosą szczegółową informację na temat np. tego, jaka klasa jest najgorzej rozpoznawana lub jakie klasy są najczęściej mylone. Błędy cząstkowe mogą być źródłem informacji, na temat tego, w jaki sposób zmodyfikować układ pomiarowy (np. zmienić położenie elektrod) aby poprawić jakość rozpoznawania. Błędy cząstkowe będą przedstawiane w postaci tabeli, której przykład znajduje się poniżej.

Numer klasy	1	2	3	4	5	6	7	8	9	Błąd [%]
1	10	0	0	0	0	0	0	0	0	0.0
2	6	3	0	0	0	0	0	1	0	9.6
3	10	0	0	0	0	0	0	0	0	13.7
4	10	0	0	0	0	0	0	0	0	13.7
5	10	0	0	0	0	0	0	0	0	13.7
6	0	0	0	0	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0	0	0
8	13	0	0	0	0	0	0	0	0	17.8
9	10	0	0	0	0	0	0	0	0	13.7
Błąd [%]	80.8	0	0	0	0	0	0	1.36	0	82.1

Tabela 7.2 Błędy cząstkowe rozpoznawania; kolorem zielonym oznaczono błędy polegające na „wypadnięciu” obiektu do innej klasy niż rzeczywista, kolorem żółtym oznaczono błędy polegające na „wpadnięciu: obiektu z innej klasy do niewłaściwej, kolorem fioletowym oznaczono błąd ogólny rozpoznawania.
Ilość obiektów uczących w każdej klasie wynosi 10.

8. Opis Programu Analizator Miopotencjałów

8.1 Ogólna koncepcja programu

Zadaniem programu *Miopotencjały* jest umożliwienie wyznaczenia podstawowych parametrów częstotliwościowych, amplitudowych i statystycznych sygnału miopotencjałów w taki sposób aby możliwe było ich wykorzystanie w procesie rozpoznawania prowadzonym w systemie on-line. Program umożliwia budowę układu pomiarowego lub rozpoznającego w oparciu o diagram przepływowy, tj. każda możliwa do wykonania operacja matematyczna na sygnale (itp. wyznaczenie transformaty Fouriera, obliczenie wartości skutecznej, średniej, itp.) jest reprezentowana w postaci układu wejściowo-wyjściowego typu MISO⁵. Budowę systemu dokonuje się łącząc poszczególne układy ze sobą (podobnie jak w programie Simulink), tak aby realizowały żadaną funkcję. Rodzaj możliwych do wykonania operacji na sygnale został tak dobrany aby umożliwić wykonanie założonego w tej pracy zestawu badań. Sygnał jest reprezentowany w postaci wektora liczb rzeczywistych. Program został napisany w języku Java, dlatego też może być używany nie tylko na platformie Microsoft Windows.

8.2 Bloki funkcjonalne

Każda funkcja (możliwa do wykonania modyfikacja sygnału) jest reprezentowana w postaci układu MISO. Poniżej zostanie przedstawiony lista wszystkich dostępnych bloków funkcjonalnych wraz z opisem w jaki sposób można je używać, w opisie założono, że sygnałem wejściowym jest uporządkowany zbiór wektorów X :

$$X = \{x^1, x^2, \dots, x^k\},$$

gdzie:

$$x^j \in \mathbb{R}^N,$$

k – ilość sygnałów wejściowych.

- SoundCard

⁵ ang. multiple inputs, single output system

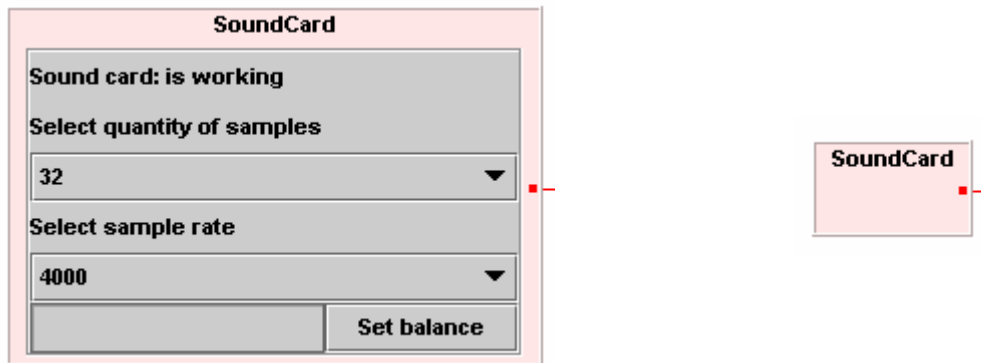
Reprezentuje w budowanym systemie wejście liniowe karty dźwiękowej umożliwiając tym samym rejestrację sygnału wejściowego poprzez wbudowane w karcie przetworniki analogowo-cyfrowe.

Parametry:

- rozmiar wektora wyjściowego podawany jako ilość próbek,
- częstotliwość próbkowania w hercach.

Dodatkowe funkcje:

- możliwość kalibracji błędu zera przetworników A/C, tj. usunięcie efekty istnienia w sygnale dodatkowej składowej stałej wynikającej z niedoskonałości użytej karty dźwiękowej.

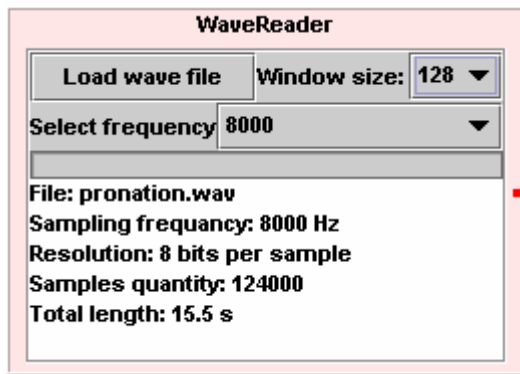


- **WaveReader**

Reprezentuje w budowanym systemie plik z zapisanym sygnałem w postaci formatu WAVE, umożliwiając tym samym analizę sygnałów w trybie off-line.

Parametry:

- rozmiar wektora wyjściowego podawany jako ilość próbek,
- częstotliwość próbkowania w hercach.
- nazwa pliku w formacie WAVE z zapisanym sygnałem.


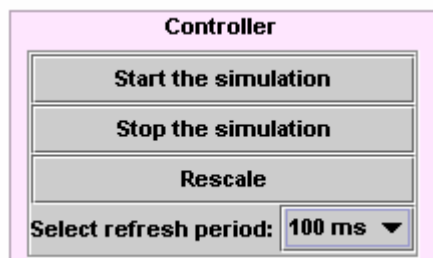


- **Controller**

Służy do sterowania systemem (musi więc w nim istnieć) , tj. umożliwia zatrzymanie lub wznowienie działania, przeskalowania wszystkich wykresów oraz ustawienia czasu co jaki będzie odświeżany widok w programie.

Parametry:

- czas co jaki następuje odświeżanie widoku.





- **DataSaver**

Umożliwia zapis rejestrowanych lub przeważanych sygnałów do pliku, w formacie umożliwiającym jego odczytanie w programie Microsoft Excel.

Parametry:

- Nazwa pliku wyjściowego do którego będą zapisywane dane.



- **Graph**



Umożliwia wizualizację rejestrowanych lub mierzonych sygnałów na ekranie komputera.

Parametry:

- Ilość wykresów na wiersz (2 lub 1).


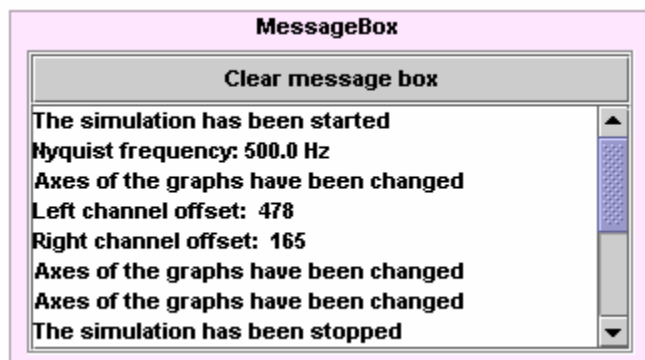
Dodatkowe funkcje:

- Automatyczna zmiana skali nadążająca za zmianą amplitudy wizualizowanego sygnału.
- Ilość sygnałów wizualizowanych jednocześnie może być dowolna.



- **MessageBox**

Pokazuje wszystkie komunikaty: informacyjne oraz o wystąpieniu błędów.



- **ClippingWindow**

Realizuje operacje okienkowania sygnału wejściowego, może być wykorzystany jako system formujący sygnał wejściowy podawany na wejście systemu realizującego transformatę Fouriera.

Parametry:

- Rodzaj okna: Prostokątne, Hanninga, Hamminga, Gaussa.




- **Fourier**

Wyznacza transformatę Fouriera (widmo) sygnału wejściowego, ilość próbek w sygnale wyjściowym jest równa połowie ilości próbek w sygnale wejściowym.



- **Merger**

Łączy wszystkie sygnały wejściowe $X = \{x^1, x^2, \dots, x^k\}$ w jeden sygnał wyjściowy $X = \{x\}$. Rozmiar wektora wyjściowego x jest równy sumie rozmiarów sygnałów x^1, x^2, \dots, x^k .



- **Spliter**

Wybiera jeden (wydziela) wskazany sygnał wejściowy i podaje go na wyjście.

Parametry:

- Numer sygnału wejściowego przekazywanego na wyjście.




- **ScalarFunction**

Umożliwia wyliczenie wybranego skalarnego parametru sygnału wejściowego.

Parametry:

- Nazwa parametru sygnału do wyznaczenia, możliwe do wyboru są: wartość skuteczna, maksymalna, minimalna, średnia, międzyszczytowa, środek ciężkości.




- **ScalarBuffer**

Umożliwia zapamiętanie zadanej ilości poprzednich wartości sygnału wejściowego w postaci kolejki FILO⁶ tworząc w ten sposób wektor wyjściowy. Sygnałem wejściowym musi być skalar dlatego też funkcja ta może być wykorzystywana tylko w połączeniu z blokiem *ScalarFunction*.

Parametry:

- Rozmiar kolejki tworzącej sygnał (bufor) wyjściowy.

⁶ ang. first in, last out




- **VectorBuffer**

Umożliwia zapamiętanie zadanej ilości poprzednich sygnałów (wektorów) wejściowego w postaci kolejki FILO wektorów wyjściowych tworząc w ten sposób sygnał wyjściowy. Sygnałem wejściowym musi być jeden wektor dlatego też bloczek ten może być wykorzystywany tylko w połączeniu z blokami: *Merger* lub *Splitter*.

Parametry:

- Rozmiar kolejki tworzącej sygnał wyjściowy.




- **VectorFunction**

Umożliwia wyliczenie wybranego statystycznego parametru zbioru sygnałów wejściowych, w odróżnieniu od bloczka *ScalarFunction* tutaj zakłada się, że sygnał wejściowy będzie składał się z więcej niż jednego wektora wejściowego, tak aby próba z której liczone są parametry statystyczne była odpowiednio duża.


Parametry:

- Nazwa parametru sygnału do wyznaczenia, możliwe do wyboru są: wartość średnia z próby, wariancja z próby.



- **Info**

Pokazuje ilość i rozmiar sygnałów wejściowych.



- **Enveloper**

Wyznacza wartość średnią (obwiednie) sygnału wejściowego według wzoru:

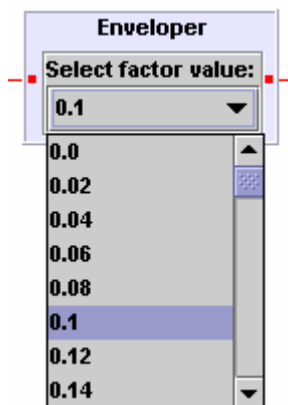
$$y^i(t) = y^i(t-1) + \alpha(x^i(t) - y^i(t-1)),$$

gdzie:

$y^i(t)$ – wartość i-tej składowej wektora wyjściowego,

x^i – wartość i-tej składowej wektora wejściowego,

α - współczynnik zadawany przez użytkownika.



• Recognizer

Realizuje algorytm rozpoznawania w oparciu o metodę k – najbliższych sąsiadów.

Parametry:

- Ilość klas do których może należeć sygnał wejściowy,
- Ilość sąsiadów,
- Rodzaj miary błędu: Euklidesowa lub Supremum.

Dodatkowe funkcje:

- Możliwość wyznaczenia błędów rozpoznawania na zbiorze uczącym i testującym.
- Podświetlanie aktualnego wyniku rozpoznawania.

Recognizer

Quantity of classes:	7	▼	Create new set	
Quantity of neighbours:	3	▼	Select metrics	Euclidesian
Class: 1	Add to learning set	Add to validating set	Name:	Stan swobodny
Class: 2	Add to learning set	Add to validating set	Name:	Prostowanie nadgarstka
Class: 3	Add to learning set	Add to validating set	Name:	Zginanie nadgarstka
Class: 4	Add to learning set	Add to validating set	Name:	Prostowanie palców
Class: 5	Add to learning set	Add to validating set	Name:	Zginanie palców
Class: 6	Add to learning set	Add to validating set	Name:	Pronacja
Class: 7	Add to learning set	Add to validating set	Name:	Supinacja

Recognizing errors matrix

Select set	Learning set	▼	Compute error					
	Class 1	Class 2	Class 3	Class 4	Class 5	Class 6	Class 7	Error [%]
Class 1	10.0	0.0	0.0	0.0	0.0	0.0	1.0	1.92307...
Class 2	1.0	2.0	1.0	1.0	0.0	0.0	2.0	9.61538...
Class 3	0.0	0.0	6.0	1.0	0.0	0.0	0.0	1.92307...
Class 4	0.0	0.0	0.0	7.0	0.0	0.0	0.0	0.0
Class 5	0.0	0.0	0.0	1.0	6.0	0.0	0.0	1.92307...
Class 6	0.0	0.0	0.0	0.0	1.0	4.0	1.0	3.84615...
Class 7	0.0	0.0	0.0	1.0	0.0	0.0	6.0	1.92307...
Error [%]	1.92307...	0.0	1.92307...	7.69230...	1.92307...	0.0	7.69230...	21.1538...


Recognizer

- **Averger**

Wartość każdej składowej wektora wyjściowego jest brana jako średnia z sąsiednich wartości odpowiedniej składowej w wektorze wejściowym

Parametry:

- Ilość punktów sąsiednich brana do obliczenia średniej.

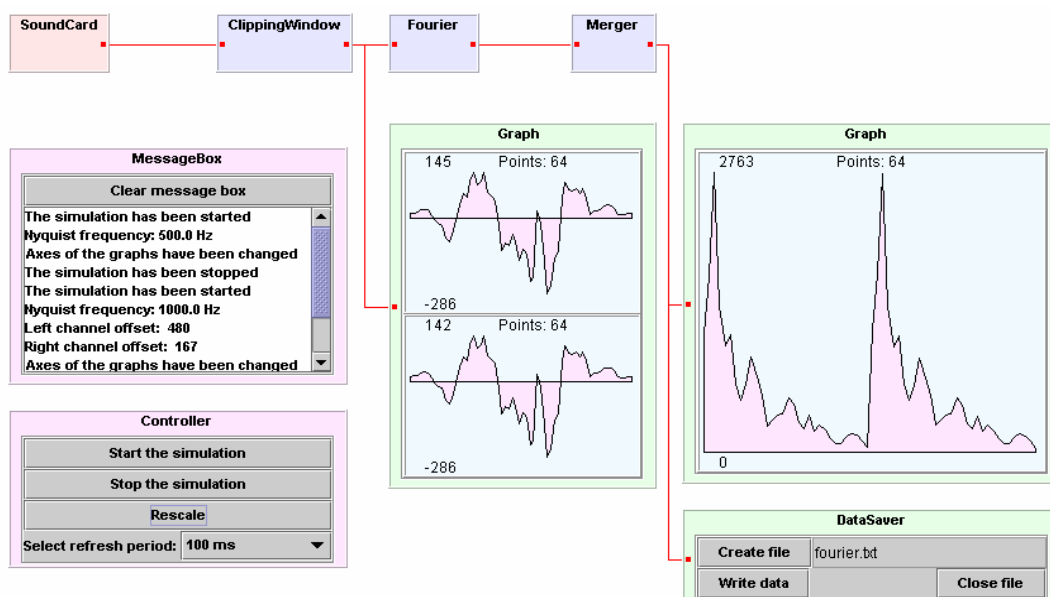


8.3 Przykłady różnych konfiguracji

Poniżej przedstawiono przykłady różnych, możliwych do zbudowania systemów do analizy miopotencjałów.

- **Konfiguracja „Fourier”**

Konfiguracja ta umożliwia wizualizację sygnału oraz zapis jego widma do pliku. Format danych zapisywanych do pliku umożliwia ich odczytanie w programie Windows Excel a tym samym dalszą obróbkę.



Plik konfiguracyjny: Fourier.dat

objects

1	Controller
2	MessageBox
3	SoundCard
4	ClippingWindow
5	Graph
6	Fourier
6	Merger
7	Graph
8	DataSaver

connections

to	4	from	3
to	5	from	4
to	6	from	4
to	7	from	6
to	8	from	7
to	9	from	7

coordinates

1	position	36	328	size	268	128	visible	yes
2	position	36	116	size	268	192	visible	yes
3	position	36	8	size	80	48	visible	no
4	position	200	8	size	108	48	visible	no
5	position	336	96	size	212	296	visible	yes
6	position	336	8	size	72	48	visible	no
7	position	480	8	size	68	48	visible	no
8	position	568	96	size	300	292	visible	yes
9	position	568	408	size	300	80	visible	yes

- **Konfiguracja „Time”**

Konfiguracja ta umożliwia wizualizację przebiegu czasowego oraz określenie stopnia przydatności reprezentacji czasowej sygnału jako wektora cech obiektu w procesie rozpoznawania.

Plik konfiguracyjny: Time.dat

objects

1	Controller
2	MessageBox
3	WaveReader
4	Merger
5	Graph
6	Recognizer

connections

to	4	from	3
to	5	from	3
to	6	from	4

coordinates

1	position	4	392	size	268	128	visible	yes
2	position	4	192	size	268	196	visible	yes
3	position	8	8	size	260	184	visible	yes
4	position	276	8	size	68	48	visible	no
5	position	364	8	size	608	124	visible	yes
6	position	364	132	size	608	532	visible	yes



9. Badania

9.1 Plan eksperymentów

Celem badań przedstawionych w tej pracy jest określenie najlepszego (z pośród badanych) sposobu ekstrakcji informacji z sygnału EMG pod kątem ich wykorzystania w sterowaniu aktywną protezą dłoni. Ocenę jakości konkretnego sposobu ekstrakcji informacji oceniano na podstawie błędu rozpoznawania dziewięciu wybranych stanów dłoni (patrz rozdział 7). Do rozpoznawania użyto algorytmu klasyfikacji k - *najbliższych sąsiadów*. Podstawą wszystkich, przedstawionych w dalszej części pracy, badań, była próba odpowiedzi na następujące pytania:

- Czy konieczne jest przejście z reprezentacji czasowej sygnału na reprezentację częstotliwościową?
- Czy widmo sygnału EMG przy nie zmiennej konfiguracji dłoni jest stałe czy też fluktuuje?
- W jaki sposób wykorzystać transformatę Fouriera, aby jakość rozpoznawania była najwyższa?
- Jaki wpływ ma orientacja elektrod EMG na jakość rozpoznawania?

9.2 Rozmieszczenie elektrod EMG

Rozmieszczenie elektrod pomiarowych jest jednym z ważniejszych czynników wpływających na jakość rozpoznawania. Można by temu problemowi poświęcić osobną pracę, badającą wpływ tylko tego parametru na jakość klasyfikacji. W tej pracy ograniczono się tylko do określenia wpływu orientacji elektrod pomiarowych na jakość rozpoznawania, tj. wyróżniono dwie konfiguracje. Pierwsza, oznaczona jako A (patrz rysunek 4.1), zawiera elektrody EMG ułożone prostopadle do włókien mięśniowych, konfiguracja tego typu jest przedstawiana w literaturze jako najlepsza przy selektywnym pomiarze miopotencjałów z jednego mięśnia [13]. Druga konfiguracja (patrz rysunek 4.1), zawiera elektrody ułożone równolegle do włókien mięśniowych, nadaje się ona gorzej do selektywnego pomiaru EMG

być może jednak lepiej do pomiaru sygnału z całej grupy mięśni, także tych odległych od miejsca zamocowania elektrod.

9.3 Baza danych sygnałów EMG

Podstawą wszystkich badań przedstawionych w tej pracy jest baza danych sygnałów EMG zarejestrowanych z użyciem zaprojektowanego i wykonanego układu pomiarowego przedstawionego w rozdziale 5. Baza ta składa się ze zbioru plików dźwiękowych nagranych w formacie *wave*. Pliki te zawierają sygnały EMG z mięśni przedramienia czterech osób (w wieku 23-25 lat) zarejestrowane dla wyszczególnionych stanów dłoni oraz konfiguracji elektrod (patrz rozdziały 4,7). Pomiary powtórzono dwukrotnie, w odstępie czasu pół godzinny, aby możliwe było skonstruowanie dwóch, niezależnych zbiorów: uczącego i testującego, potrzebnych do oceny jakości informacji uzyskanych z EMG. Baza danych jest dostępna na płycie CD-ROM.

9.4 Eksperymenty

▪ Doświadczenie nr 1

Jedno z pierwszych doświadczeń mające określić jaka postać wektora cech jest odpowiednia w badanym problemie, polegało na próbie bezpośredniego wykorzystania przebiegów czasowych sygnałów EMG jako wektorów cech i użycie ich jako obiektów uczących. Innymi słowy, w doświadczeniu tym próbowano odpowiedzieć na pytanie: czy zmiana reprezentacji z czasowej na częstotliwościową jest w ogóle konieczna. Poniżej przedstawiono warunki w jakich przeprowadzono badania wraz z ich wynikami.

Częstotliwość próbkowania [Hz]	1000
Rozmiar okna w każdym kanale [próbek]	128
Rozmiar wektora cech	256
Ilość obiektów uczących w każdej klasie	10
Wartość parametru k	3
Plik konfiguracyjny	Time.dat

Tabela 9.1 Parametry doświadczenie nr 1.

Numer klasy	1	2	3	4	5	6	7	8	9	Błąd [%]
1	10	0	0	0	0	0	0	0	0	0.0
2	6	3	0	0	0	0	0	1	0	9.6
3	10	0	0	0	0	0	0	0	0	13.7
4	10	0	0	0	0	0	0	0	0	13.7
5	10	0	0	0	0	0	0	0	0	13.7
6	0	0	0	0	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0	0	0
8	13	0	0	0	0	0	0	0	0	17.8
9	10	0	0	0	0	0	0	0	0	13.7
Błąd [%]	80.8	0	0	0	0	0	0	1.36	0	82.1

Tabela 9.2 Błąd rozpoznawania w doświadczeniu nr 1.

Przedstawione wyniki jasno pokazują fakt, że reprezentacja czasowa nie nadaje się w procesie rozpoznawania jako wektor cech. Błąd rozpoznawania jest bardzo wysoki i wynosi ponad 82%, praktycznie rzecz biorąc, niemalże wszystkie obiekty są klasyfikowane jako należące do klasy pierwszej.

▪ Doświadczenie nr 2

Kolejne doświadczenie miało na celu określenia jakości rozpoznawania w przypadku kiedy wektorem cech było niezmodyfikowane widmo sygnału EMG.

Częstotliwość próbkowania [Hz]	1000
Rozmiar okna w każdym kanale [próbek]	128
Rozmiar wektora cech (ilość harmoniczných)	128
Ilość obiektów uczących w każdej klasie	25
Wartość parametru k	3
Plik konfiguracyjny	Fourier_2.dat

Tabela 9.3 Parametry doświadczenia nr 2.

Numer klasy	1	2	3	4	5	6	7	8	9	Błąd [%]
1	12	0	0	0	0	4	0	4	0	3.6
2	0	25	0	0	0	0	0	0	0	0.0
3	0	0	23	0	1	0	1	0	0	0.9
4	0	1	0	5	5	14	0	0	0	9.0
5	0	7	0	1	6	9	1	0	1	8.6
6	0	0	0	2	4	3	8	0	8	10.0
7	0	0	0	5	0	16	2	0	2	10.0
8	0	3	0	0	3	3	0	15	1	4.5
9	0	11	0	1	12	2	1	0	8	7.7
Błąd [%]	0.0	5.4	0.0	4.0	11.3	21.7	5.0	1.8	5.4	54.8

Tabela 9.4 Błąd rozpoznawania w doświadczeniu nr 2.

Jakość rozpoznawania przy wykorzystaniu widma sygnału jest już wyższa od tej uzyskanej w doświadczeniu nr 1. Jednak błąd rozpoznawania na poziomie 54 % to zdecydowanie za dużo aby można było stwierdzić, że ten sposób uzyskiwania wektora cech jest wystarczający w sterowaniu bioprotezą. Główną przyczyną tak niskiej jakości rozpoznawania są duże fluktuacje widma (patrz rozdział 4), pewną próbą poradzenia sobie z tym problemem jest uśrednianie widma sygnału z kilku ostatnich okien i w ten sposób tworzenie wektora cech. Ten pomysł zostanie przebadany w następnym doświadczeniu.

▪ Doświadczenie nr 3

10. Podsumowanie

11. Literatura

- [1] J. Szabatin, „*Podstawy teorii sygnałów*”, wydanie drugie, Wydawnictwa Komunikacji i Łączności, Warszawa 1990.
- [2] M. Kurzyński, „*Rozpoznawanie obiektów – metody statystyczne*”, Oficyna Wydawnicza Politechniki Wrocławskiej, Wrocław 1997.
- [3] J. A. Moczko, L. Kramer, „*Cyfrowe metody przetwarzanie sygnałów biomedycznych*”, Wydawnictwo Naukowe Uniwersytetu IM. Adama Mickiewicza w Poznaniu, Poznań 2001.
- [4] S. Grimnes, O. G. Martinsen, „*Bioimpedance and bioelectricity basics*”, Academic Press, 2000.
- [5] P., Horowitz, W., Hill, „*Sztuka elektroniki*”, wydanie trzecie, Wydawnictwa komunikacji i łączności, Warszawa 1996.
- [6] D.Nishikawa, W.Yu, H.Yokoi, Y.Kakazu, „*EMG Prosthetic Hand Controller using Redl-time Learning Method*”, 1999, IDEE Systems, Man and Cybernetics Conference Tokio.
- [7] K.Englehart, B.Hudgins, P.A.Parker, M.Stevenson „*Classification of the Myoelectric Signal using Time-Frequency Based Representations*”, 1999, Medical Engineering and Phisics on Inteligent Data Analysis in Electromyography and Electroneurogrphy.
- [8] B., Eckel, „*Thinking in Java*”, wydanie drugie, Wydawnictwo Hellion, Gliwice 2001.
- [9] K., Englehart, B., Hudgins, P., Parker, „*A Wavelet Based Continuous Classification Scheme for Multifunction Myoelectric Control*”, <http://citeseer.com>
- [10] J. Abbas, „*Neural Networks for Physiological Control – The Biomedical Engineering Handbook*”, 2000, CRC Press LLC.
- [11] J. Nagel, „*Biopotential Amplifiers– The Biomedical Engineering Handbook*”, 2000, CRC Press LLC.
- [12] M. Neuman, „*Biopotential Electrodes – The Biomedical Engineering Handbook*”, 2000, CRC Press LLC.
- [13] C., De Luca, „*Surface Electromyography: Detection and Recording*”, 2002, DelSys Incorporated, <http://www.delsys.com>

- [14] C., De Luca, *"The Use of Surface Electromyography in Biomechanics"*, 1997, DelSys Incorporated, <http://www.delsys.com>.
- [15] *"Fundamental Concepts of Data Acquisition"*, 2001, DelSys Incorporated, <http://www.delsys.com>.
- [16] S., Busz, *„Zastosowanie sieci neuronowych do sterowania bio-manipulatorem"*, praca magisterska, Politechnika Wrocławska, Wrocław 2003.

12. DODATEK A - Skrócony opis układu INA116
