

Analiza i klasyfikacja biosygnalów

Spis treści wykładu 4

- podstawowe pojęcie Interfejsu Człowiek-Maszyna;
- własności anatomiczno/fizjologiczne organizmu umożliwiające biosterowanie;
- elektromiografia powierzchniowa – detekcja i zapis;
- rozpoznawanie intencji człowieka – analiza i klasyfikacja biosygnalów;
- bioproteza – przykład biocybernetycznej maszyny;

Problemy sterowania bioprotezą ręki

Sterowanie bioprotezą ręki nie jest pojedynczym, dobrze określonym problemem, lecz raczej zbiorem wielu różnych problemów - wynikających m.in.:

- ze specyfiki detekcji intencji człowieka (interfejs człowiek proteza),
- geometrii (antropomorfizm), masy oraz własności kinematyki (i dynamiki) struktury mechanicznej protezy,
- jej interakcji z chwytanymi obiektami, oraz
- potrzeby pomiaru tej interakcji, i wykorzystania tej informacji do sterowania chwytem (sprężenie zwrotne), a także
- do symulacji podstawowych wrażeń czuciowych dotyku, nacisku, poślizgu (interfejs proteza człowiek).

Problemy składające się na sterowanie bioprotezą występują w różnych „*miejscach*” procesu sterowania - na określonych poziomach jego struktury i na określonych etapach jego realizacji.

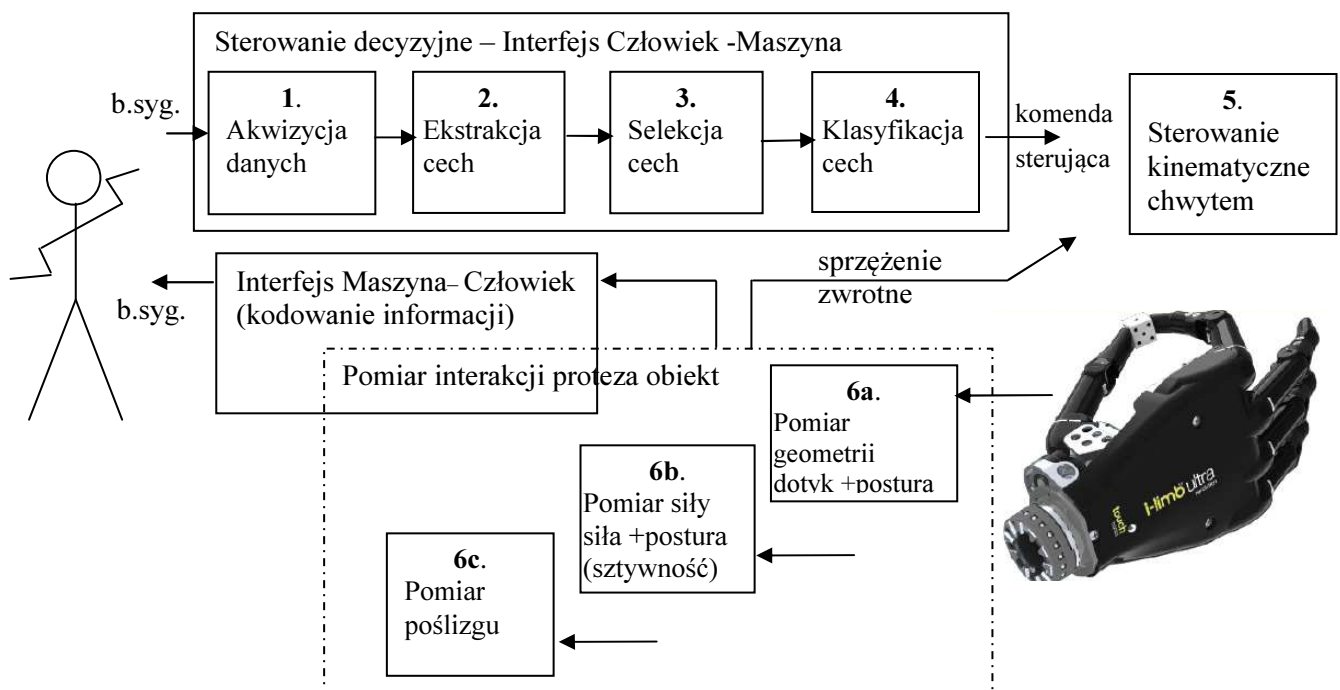
Są one modelowane i rozwiązywane w różny sposób.

Sterowanie bioprotezą - proces wielopoziomowy

Wśród poziomów procesu sterowania bioprotezą, możemy wyróżnić:

- a) sterowanie decyzyjne;
- b) sterowanie kinematyczne;
- c) pomiar stanu protezy i interakcji proteza obiekt, oraz
- d) przekaz czucia tego stanu do człowieka.


Sterowanie bioprotezą - procesy wieloetapowe



1 Akwizycja danych

Idea pomiaru różnicowego

$$\text{SNR} = \text{signal-to-noise ratio}$$



S_1, S_2 – sygnał użyteczny, Z – zakłócenia

System pomiarowy – sensor zespolony



Widok sensora zespolonego: (a) od strony elektrod i komory akustycznej,
(b) widok wnętrza ze wzmacniaczem wstępnym


System pomiarowy – kompletny układ części analogowej



Badane ruchy




1 - długopis z kubka



2— śrubka




3 – potencjometr



4 - szklanka bez ucha



5 - kubek za ucho 2 palcami



6 - czajnik za rączkę



7 - karta z kubeczka



8- komórka z obrotem



9 – myszka




10 - komórka bez obrotu




11 - walizkowy (poziomy)

Baza Danych

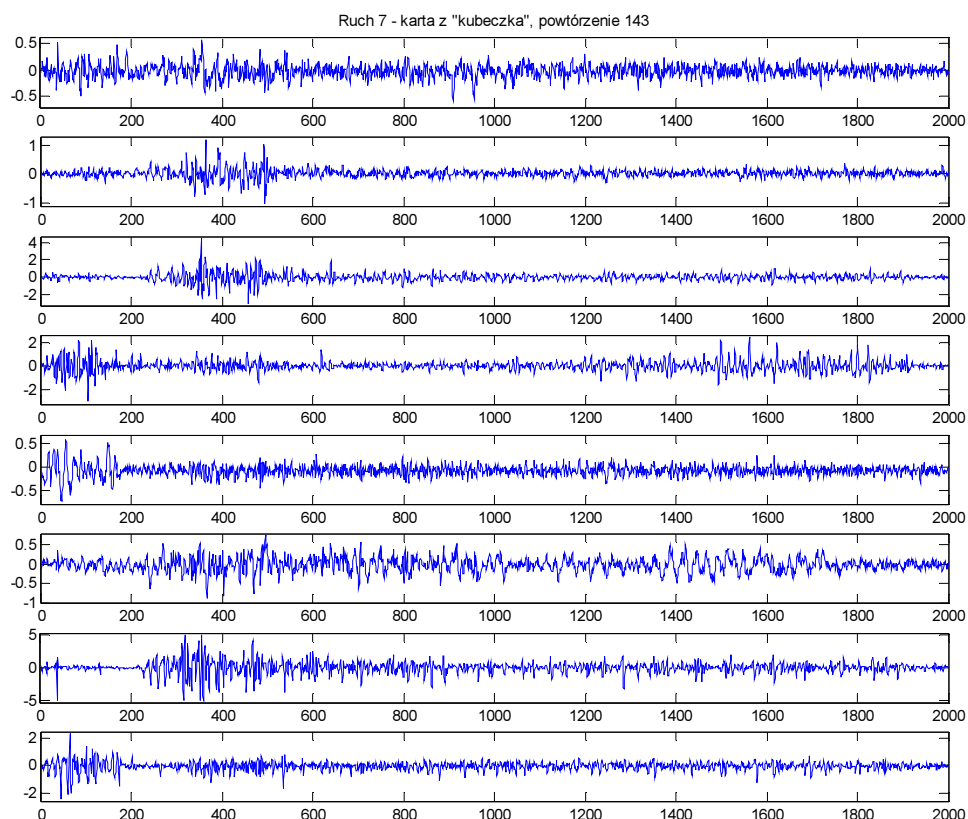
- Dla każdego z 11 ruchów wykonano 200 powtórzeń
- Każde powtórzenie trwało 2s
- Sygnały były rejestrowane z częstotliwością 1kHz
- Rejestrowano zarówno sygnały EMG jak i MMG



(a) sygnał EMG;



(b) sygnał MMG





Przykładowy sygnał EMG zarejestrowany przez kolejne kanały systemu pomiarowego

W biosterowaniu wykorzystuje się sygnały EMG zarejestrowane z elektrod powierzchniowych i wstępnie przetworzone poprzez odfiltrowanie elektrycznych zakłóceń zewnętrznych, oraz sygnały MMG zarejestrowane mikrofonami.

Wybór punktu onset

Celem identyfikacji momentu *onset* jest określenie punktu w czasie - kiedy sygnał zaczyna opisywać zdarzenie, które będzie przedmiotem klasyfikacji. Detekcja onset jest istotna dla dalszego procesu analizy i klasyfikacji. Sygnały po odrzuceniu obserwacji przed momentem onset są umieszczane w Bazie Danych.



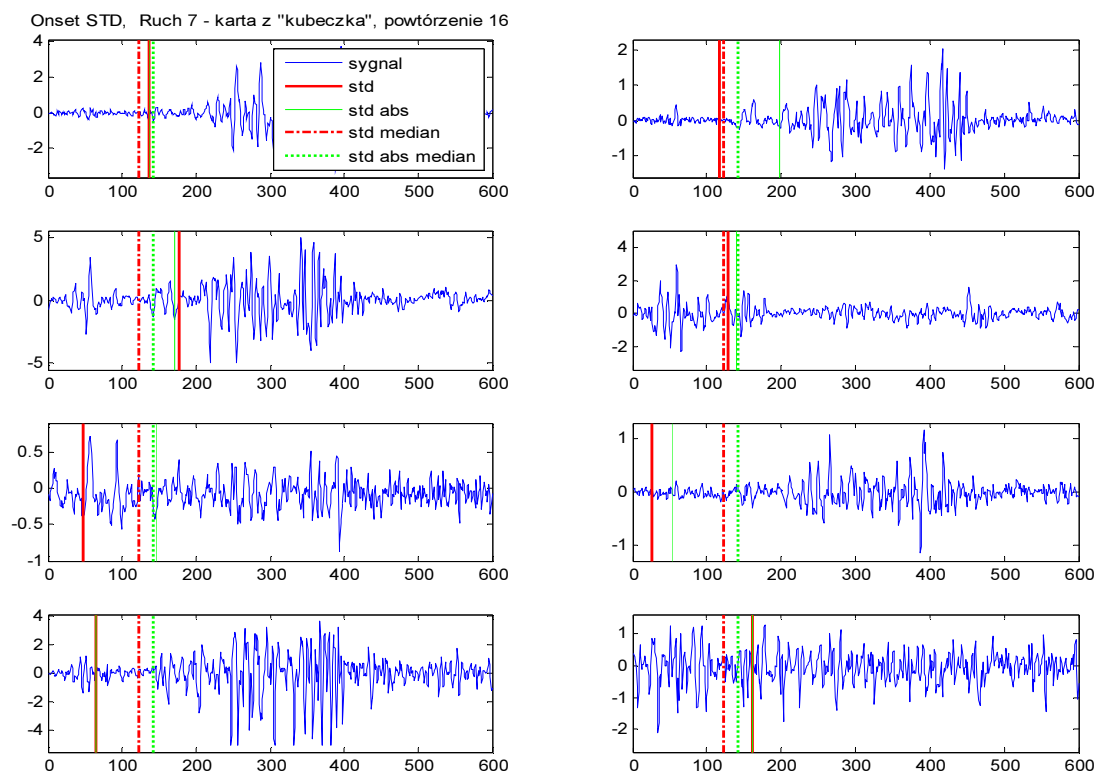
Zróznicowanie powtórzeń jednego rodzaju ruchu zarejestrowanych na jednym kanale

Na wykresie widać 16-scie powtórzeń jednego rodzaju ruchu, z jednego kanału. Można zaobserwować zmienność sygnału opisującego ten sam ruch w zależności od powtórzenia, a przede wszystkim zróżnicowanie ze względu na „rozpoczęcie” ruchu. Wyznaczanie optymalnego punktu onset można realizować metodami progowymi, np.:

- średnia modułu sygnału w oknie
- odchylenie standardowe w oknie
- porównanie ze średnią sygnału

Algorytm A - Średnia modułu sygnału w oknie

- Określ długość okna
- Określ próg (K) graniczny identyfikujący start sygnału
- Wyznacz średnią modułu sygnału (avg_abs_start) na początku sygnału na zbiorze o długości okna
- Wyznaczaj kolejne średnie modułu sygnału ($avg_abs_calc_i$) przesuwając okno w kierunku końca sygnału po indeksie sygnału (i)
- Wykonaj porównanie $avg_abs_calc_i > K * avg_abs_start$, jeżeli warunek jest spełniony indeks rozpoczęcia okna i będzie punktem onset



Zróżnicowanie punktu onset ze względu na sposoby wyboru w podejściu bazującym na odchyleniu standardowym (alg B)


2 Ekstrakcja cech

Sygnał w nieprzetworzonej postaci niesie ze sobą bardzo wiele informacji, które trudno wykorzystać bezpośrednio (trudno odczytać cechy dotyczące obserwowanego ruchu). Ma też zbyt duży wymiar dla procesu klasyfikacji. Dlatego przeprowadza się proces ekstrakcji cech.

Celem ekstrakcji cech jest wyłonienie najbardziej istotnej informacji zawartej w sygnale przez odnalezienie i obliczenie jego najbardziej użytecznych (dla rozpoznawania) parametrów. Cechy można wyznaczać między innymi w następujących dziedzinach:


- dziedzinie czasu, np.:
 - liczba przejść przez zero / progowanie
 - momenty sygnału
 - autokorelacja
 - współczynniki ciągu AR (autoregresji)
- dziedzinie częstotliwości, np.:
 - FFT (szybka transformata Fouriera)
- dziedzinie czasowo-częstotliwościowej, np.:
 - DWT (dyskretna transformata falkowa)
 - STFT (krótkoczasowa transformata Fouriera)

Krótkoczasowa transformata Fouriera (STFT) stanowi numeryczną implementacją dyskretną transformaty Fouriera, która rozkłada funkcję okresową na szereg funkcji okresowych tak, że uzyskana transformacja podaje w jaki sposób poszczególne częstotliwości składają się na pierwotną funkcję.



Dyskretna transformata falkowa (DWT)

Dekompozycja DWT (db4), 7 poziomów, Ruch 7 - chwyt płaski obustronny (karty bankomatowej leżącej na kubku), powtórzenie 20, kanał 2



Przykładowa dekompozycja sygnału transformacją DWT 7 rzędu z zastosowaniem falek Daubechies4

3 Selekcja (redukcja) cech


Celem tego etapu jest zmniejszenie badanego zbioru danych, tak aby uprościć docelowy model klasyfikacji. Selekcja polega na wyborze cech najistotniejszych z punktu widzenia siły dyskryminacyjnej, tj. odrzucane są cechy słabo związane z klasyfikacją lub skorelowane z innymi, już uwzględnionymi w modelu cechami. Z reguły wybierane są cechy, których rozrzut dla powtórzeń sygnału tej samej klasy jest najmniejszy, a dla sygnałów z różnych klas duży (dobra separowalność klas). Natomiast redukcja polega na wyznaczeniu nowych cech z wykorzystaniem oryginalnych (na podstawie tych zidentyfikowanych), nieskorelowanych i zapewniających maksymalną separowalność klas.

Stosowane są między innymi następujące metody:

– ***Sequential Forward Selection*** - jest to metoda iteracyjna umożliwiająca przeprowadzenie szacunku wpływu pojedynczych cech na efektywność klasyfikacji. Punktem startowym metody jest wyłonienie pojedynczej najlepszej cechy, a następnie dodawanie kolejnych cech i ocena (po każdym dodaniu), która cecha wniosła najwięcej nowej informacji do opisu analizowanego zjawiska.

– ***Sequential Backward Selection*** - punktem startowym metody jest przyjęcie wszystkich cech, a następnie usuwanie poszczególnych zmiennych i ocena po osunięciu których nastąpiła najmniejsza utrata informacji w opisie zjawiska.

– ***Principal Components Analysis*** - jest metodą opartą na założeniu, że w posiadanym zbiorze danych zmienne są nadmiernie skorelowane i wiele informacji jest duplikowanych. **PCA** polega na tworzeniu nowych zmiennych, które są kombinacjami liniowymi istniejących. Nowe zmienne są tworzone w taki sposób, aby zawierały jak najwięcej informacji, a miarą informacji jest *wariancja cechy*, którą wyjaśniają. W ten sposób otrzymuje się szereg nowych zmiennych/cech – principal components. Do klasyfikacji można wybrać początkowe składowe główne, które wyjaśniają wariancję do poziomu powyżej 99%.



Idea algorytmu PCA w przestrzeni dwuwymiarowej (źródło:


<http://stats.stackexchange.com/questions/2691/making-sense-of-principal-component-analysis-eigenvectors-eigenvalues>)

4 Klasyfikacja

W procesie klasyfikacji wykorzystano algorytmy kNN i LVQ, a efektywność klasyfikacji była oceniana z perspektywy błędu klasyfikacji na zbiorze testowym, który stanowił 50% posiadanego zbioru danych.

Algorytm k _Najbliższych_Sąsiadów


kNN – algorytm najbliższych sąsiadów nie polega na tworzeniu modelu, ale na odnalezieniu w zbiorze uczącym wektora cech najbliższego temu dla którego chcemy przewidzieć klasyfikację. Istotne dla skuteczności metody jest określenie metryki do pomiaru odległości oraz liczby najbliższych sąsiadów decydujących o klasyfikacji.



Idea algorytmu kNN w zależności od parametru k liczby sąsiadów

Sieć neuronowa LVQ

Sieć LVQ (*Learning Vector Quantization*) składa się z pojedynczej warstwy zawierającej ρ neuronów. Każdy i -ty neuron jest połączony ze wszystkimi składowymi wektora wejściowego x - poprzez wektor wag w_i .



Struktura sieci LVQ.

Jak zostało nadmienione, proces ekstrakcji cech daje w każdym cyklu, 36-elementowy wektor cech x^- .

Każdy wektor cech oraz każdy neuron są związane z określoną klasą q^* (klasą pożądanego ruchu elementarnego).

Do zapewnienia właściwego funkcjonowania protezy, opracowano sieć z 36 wejściami, oraz 90 neuronami - po 9 neuronów na każdą z rozpoznawanych klas.

Mechanizm rozpoznawania jest podobny jak w metodzie *K-Nearest_Neighbour*, dla $K = 1$. Każdorazowo po podaniu na wejście, wektor x^- zostaje zakwalifikowany do klasy, z którą związany jest neuron wygrywający $\omega = w_i$, (czyli w_i , najbliższy x^- , w sensie przyjętej metryki):

$$\omega = \min_{1 \leq i \leq \rho} d(w_i, x^-). \quad (8)$$

Zaimplementowane wartości wag (tzw. codebook), zostały wyznaczone drogą uczenia sieci z wykorzystaniem zbioru uczącego uzyskanego w wyniku przeprowadzonych eksperymentów.

Eksperymentalne badanie algorytmów analizy i klasyfikacji sygnałów EMG

